

Deep Learning for Sequential Recommendation:算法、影响因素和评估

方慧, 上海财经大学RIIS&SIME, 中国 张丹宁*, 上海财经大学SIME, 中国 舒一恒, 东北大学软件学院, 中国

郭桂兵, 东北大学软件学院, 中国

在顺序推荐领域, 基于深度学习 (DL) 的方法在过去几年中受到了广泛的关注, 并超过了传统的模型, 如基于马尔科夫链和基于因子化的模型。然而, 对基于DL的方法的系统研究很少, 特别是关于如何设计一个有效的DL模型用于顺序推荐。鉴于此, 本调查通过考虑上述问题, 重点研究基于DL的顺序推荐系统。具体来说, 我们说明了顺序推荐的概念, 提出了现有算法在三种行为顺序方面的分类, 总结了影响基于DL模型性能的关键因素, 并进行了相应的评估来展示和证明这些因素的影响。我们通过系统地概述这一领域的未来方向和挑战来结束这项调查。

CCS的概念。- 信息系统 → 推荐人系统。

其他关键词和短语: 顺序推荐、基于会话的推荐、深度学习、影响因素、调查、评价

ACM参考格式。

方慧, 张丹宁, 舒一恒, 和郭贵兵。2020.Deep Learning for Sequential Recommendation:算法、影响因素和评价. *ACM Transactions on Information Systems* 1, 1, Article 1 (January 2020), 41 pages. <https://doi.org/10.1145/3426723>

1 简介

随着信息技术 (IT) 的普及, 推荐系统早已被认为是解决信息过载问题的一个有效和强大的工具。它使用户很容易根据自己的喜好过滤和定位信息, 并允许在线平台广泛宣传他们产生的信息。大多数传统的推荐系统都是基于内容和协作过滤的系统。他们努力在用户和项目之间的显性或隐性互动的基础上模拟用户对项目的偏好。具体来说, 他们倾向于利用用户的历史互动来学习他/她的静态偏好, 并假设历史序列中所有的用户与物品的互动都是同等重要的。

* 通讯作者

作者的地址。Hui Fang, RIIS & SIME, Shanghai University of Finance and Economics, China, fang.hui@mail.shufe.edu.cn; Danning Zhang, SIME, Shanghai University of Finance and Economics, China, zhangdanning5@gmail.com; Yiheng Shu, Software College, Northeastern University, China, shuyiheng29@gmail.com; Guibing Guo, Software College, Northeastern University, China, guogb@swc.neu.edu.cn.

允许为个人或课堂使用本作品的全部或部分内容制作数字或硬拷贝, 但不得以营利或商业利益为目的制作或分发拷贝, 且拷贝首页须注明本通知和完整的引文。除作者外, 本作品中其他部分的版权必须得到尊重。允许摘录并注明出处。以其他方式复制, 或重新发表, 张贴在服务器上或重新分发到名单上, 需要事先获得特别许可和/或支付费用。请从 permissions@acm.org。

© 2020 版权由所有者/作者持有。出版授权给ACM。1046-8188/2020/1-art1

\$15.00

<https://doi.org/10.1145/3426723>

然而, 这在现实世界的场景中可能不成立, 因为用户的下一个行为不仅取决于静态的长期偏好, 而且在很大程度上依赖于当前的意图, 而这可能是由一小部分最近的交互推断和影响的。另一方面, 传统的方法总是忽略了考虑用户交互之间的顺序依赖, 导致对用户偏好的不准确建模。因此, 顺序推荐在学术研究和实际应用中已经变得越来越流行。

顺序推荐 (与[77]中的顺序感知推荐相同) 也与基于会话或会话感知的推荐有关。考虑到后两个术语可以被看作是顺序推荐的子类型[77], 因此我们使用更广泛的术语 *顺序推荐* 来描述探索顺序数据的任务。

对于顺序推荐来说, 除了像传统推荐那样捕捉用户在不同会话中的长期偏好外, 同时对用户在一个会话 (或一个短序列) 中的短期兴趣进行建模以实现准确推荐也是极其重要的。关于一个会话中不同交互之间的时间依赖性以及不同会话之间行为模式的相关性, 传统的顺序推荐系统特别希望采用适当的和有效的机器学习 (ML) 方法来对顺序数据进行建模, 例如马尔科夫链[21]和基于会话的 KNN[31, 39], 这些方法被批评为不完整的建模问题, 因为它们不能通过结合不同的会话来彻底地建模用户的长期模式。





图1.2015-2019年关于基于DL的顺序推荐的arXiv文章的数量。

近年来, 深度学习 (DL) 技术, 如循环神经网络 (RNN), 在自然语言处理 (NLP) 方面获得了巨大的成就, 证明了它们在处理顺序数据方面的有效性。因此, 它们在顺序推荐方面引起了越来越多的兴趣, 许多基于DL的模型已经取得了最先进的性能[147]。2015-2019年发布的相关arXiv文章的数量如图¹¹所示, 我们可以看到, 人们对基于DL的顺序推荐的兴趣有了惊人的增长。此外, 顺序推荐的常见应用领域包括电子商务 (如RecSys

¹ 我们在arXiv.org上搜索了2020年6月使用相关关键词以及它们的组合的文章, 如 *顺序推荐*、*深度学习* 和 *基于会话的推荐*。由于2020年的数据不完整, 我们没有在图1中报告它的数据。图2考虑了所有的文章。



越来越多的新技术和改进的结构已经被应用于促进基于DL的顺序推荐。然而，我们发现，基于DL的模型仍然有一些共同的缺点。例如，许多现有的工作并没有把项目和用户放在同一个重要的层面上考虑，也就是说，他们在很大程度上强调了项目的表述，但缺乏对用户表述的精心设计。此外，他们只是将所有的交互视为一种类型，而不是区分不同的类型。更重要的是，尽管更先进的技术已被越来越多地采用，但仍不清楚这一领域的真正进展，因为只有复杂的DL结构不可能产生更好的性能[19]。在这种情况下，揭示导致有用的基于DL的顺序推荐系统的影响因素变得极为必要。因此，我们倾向于在本调查中彻底讨论改进的技术和上述问题。本调查的贡献总结如下。

- 我们从已部署的DL技术方面对顺序推荐进行了全面概述。就我们所知，这是第一篇关于基于DL的顺序推荐的调查文章。
- 我们为顺序推荐提出了一个原始的分类框架，与三种不同的推荐情况相关，这可以为现有的分类法在顺序推荐方面作出贡献。
- 我们总结了典型的基于DL的顺序推荐的影响因素，并通过一个精心设计的实证研究证明了它们对顺序推荐在推荐准确性方面的影响，这可以作为顺序推荐研究和实践的指导。此外，我们的实验设置和实验库（包括源代码和数据集）可以被看作是未来研究的一个有价值的测试平台。

4movielens.org.

- 我们总结了现有的基于DL的顺序推荐中的相当多的开放问题, 并概述了未来的方向。

1.1 相关调查

已经有一些关于基于DL的推荐或顺序推荐的调查。对于基于DL的推荐, Singhal等人[92]总结了基于DL的推荐系统, 并将其分为三种类型: 协作过滤、基于内容和混合类型。Batmaz等人[8]从DL技术和推荐问题的角度对基于DL的推荐进行了分类和总结, 并对基于会话的推荐做了简要介绍。Zhang等人[147]进一步讨论了最先进的基于DL的推荐系统, 包括几种基于RNN的顺序推荐算法。对于顺序推荐, Quadrona等人[77]提出了一个推荐任务和目标的分类, 并总结了现有的解决方案。Wang等人[121]总结了顺序推荐系统的主要挑战、进展和未来方向。以更全面的方式[119], 他们进一步说明了基于会话的推荐系统(SBRS)的价值和意义, 并提出了一个分层的框架来对问题和方法进行分类, 包括一些基于DL的方法。

然而, 据我们所知, 我们的调查是第一次具体和系统地调查了
本文总结和探讨了基于DL的顺序推荐, 并通过对几个真实数据集的实验评估的全面展示, 讨论了常见的影响因素。实验结果和结论可以进一步指导未来关于如何为顺序推荐设计有效的DL模型的研究。

1.2 本调查的结构

本调查的其余部分组织如下。在第2节中, 我们提供了基于DL的顺序推荐系统的全面概述, 包括对顺序推荐任务的仔细推敲。在第3节中, 我们介绍了每个推荐任务的代表性算法的细节。在第4节中, 我们总结了现有的基于DL的顺序推荐的影响因素, 然后在第5节中对真实数据集进行了全面的评估。最后, 我们在第6节中提出了基于DL的顺序推荐的开放问题和未来的研究方向, 从而结束了这次调查。

2 顺序建议概述

在本节中, 我们对顺序推荐进行了全面的概述。首先, 我们澄清了相关概念, 然后正式描述了顺序推荐任务。最后, 我们阐述并比较了用于顺序推荐的传统ML和DL技术。

2.1 概念定义

为了便于理解, 我们首先正式定义了 *行为对象* 和 *行为类型*, 以区分连续数据中的不同用户行为。

定义2.1.行为对象是指用户选择互动的项或服务, 通常以一个项或一组项的ID呈现。它还可能与其他信息相关联, 包括文字描述、图像和交互时间。为了简单起见, 我们在下面的章节中经常使用 *item(s)* 来描述行为对象。

定义2.2.行为类型是指用户与物品或服务互动的方式, 包括 *搜索*、*点击*、*添加到购物车*、*购买*、*分享*等。





图3.顺序推荐的示意图。 $\square\square$ ：行为类型， $\square\square$ ：行为对象。一个行为 $\square\square$ 由一个2元组表示，即 $\square\square = (\square\square, \square\square)$ 。一个行为序列（即行为轨迹）是一个按时间顺序排列的2元组的列表。

鉴于这些概念，一个行为可以被认为是一个行为类型和一个行为对象的组合，即用户通过一个行为类型与一个行为对象进行互动。因此，一个行为轨迹可以被定义为一个由多个用户行为组成的行为序列（或行为会话）。一个典型的行为序列如图3所示。具体来说，一个行为（ $\square\square$ ）由一个2元组（ $\square\square, \square\square$ ）表示，即一个行为类型 $\square\square$ 和行为对象 $\square\square$ 。产生序列的用户可以是匿名的，也可以通过他/她的ID来识别。序列中的行为是按时间顺序排序的。当一个行为涉及到多个对象时（如购物篮中记录的物品），购物篮中的对象可能不按时间排序，然后多个购物篮一起构成一个行为序列。应该注意的是，序列和会话在本文中是可以互换使用的。

因此，顺序推荐系统是指以用户的行为轨迹为输入，然后采用推荐算法向用户推荐合适的物品或服务的系统。输入的行为序列 $\{\square_1, a_2, a_3, \dots, a_i\}$ 是多态的，因此可以分为三种类型⁵：基于经验的行为序列、基于交易的行为序列和基于交互的行为序列，具体阐述如下。



基于经验的行为序列。在基于经验的行为序列中（见图4），用户可以通过不同的行为类型与同一个对象（例如，项目 \square_i ）多次互动。例如，一个用户与一个物品的互动历史可能如下：首先搜索相关的关键词，然后在结果页上点击感兴趣的物品，接着查看物品的细节。最后，用户可能与他/她的朋友分享该物品，如果他/她喜欢，就把它加入购物车。不同的行为类型以及它们的顺序可能表明用户的不同意图。例如，点击和查看只能表明用户的低度兴趣，而在购买之前（或之后）出现的分享行为可能意味着用户对获得（或拥有）该物品的强烈愿望（或满意）。对于这种类型的行为序列，预计一个模型可以捕捉到用户的基本

⁵ 我们以更细的粒度来讨论序列，目的是为了更好地理解序列推荐任务。我们主要根据序列中涉及的行为类型和对象来命名这三种类型。我们认为，这可以促进网络结构的更好设计，以处理相应的序列进行顺序推荐。

不同的行为类型所表明意图。这里的目标是预测用户在给定项目后的下一个行为类型。




图5.基于交易的行为序列。

基于交易的行为序列。基于交易的行为序列（见图5）记录了用户与之互动的一系列不同的行为对象，但其行为类型相同（即购买）。在实践中，购买是网上卖家最关心的一个问题。因此，有了基于交易的行为序列作为输入，顺序推荐系统的目标是考虑到用户的历史交易，推荐用户将购买的下一个对象（物品）。




图6.基于互动的行为序列。

基于互动的行为序列。基于互动的行为序列可以被看作是基于经验的行为序列和基于交易的行为序列的混合体（见图6），也就是说，它是前两种类型的概括，更接近于真实场景。也就是说，它同时由不同的行为对象和不同的行为类型组成。在基于交互的行为序列建模中，预计推荐系统会更多地了解用户的偏好

现实地，包括由不同的行为类型和不同的行为对象所暗示的偏好所表达的不同用户意图。

其主要目标是预测用户将与之互动的下一个行为对象。

2.2 顺序推荐任务

在正式定义顺序推荐任务之前，我们首先总结一下文献中的两个代表性任务（如图7所示）：下一个项目推荐和下一个篮子推荐。在下一个项目推荐中，一个行为只包含一个对象（即项目），它可能是一个产品、一首歌、一部电影或一个地点。相反，在下一个篮子推荐中，一个行为包含一个以上的对象。

然而，尽管上述推荐任务的输入是不同的，但它们的目标大多是相同的。具体来说，它们都致力于为用户预测下一个项目，而最流行的输出形式是前N个排名的项目列表。排名可以通过概率、绝对值或相对排名来确定，而在大多数情况下，都采用softmax函数来生成输出。Tan等人[103]进一步提出了一个嵌入版的softmax输出，用于快速预测，以适应推荐中大量的项目。

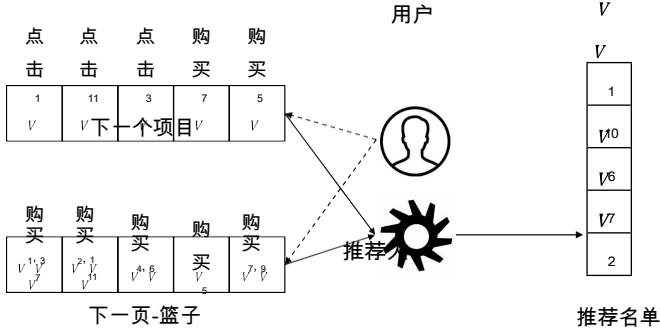


图7.下一个项目和下一个篮子的推荐。

在本文中，我们认为顺序推荐的任务是在三种类型的用户行为序列（输入）的基础上生成一个个性化的排名项目列表，这些序列可以正式定义为。

$$(\square_1, \square_2, \square_3, \dots, \square_\square) = \square(\square_1, \square_2, \square_3, \dots, \square_\square, \square) \quad (1)$$

其中，输入是行为序列 $\{\square_1, \square_2, \square_3, \dots, \square_\square\}$ ， \square 指序列中相应的用户， \square_\square 表示项目 \square 在时间 $\square + 1$ 时被用户 \square 喜欢的概率。 \square 表示候选项目的数量。换句话说，顺序推荐的任务是学习一个复杂的函数 \square ，用于准确预测用户 \square 在时间 $\square + 1$ 时选择每个项目 \square 的概率，基于输入行为序列和用户特征。

根据定义，并考虑到三种类型的行为序列，我们因此将序列推荐任务分为三类：*基于经验的序列推荐*、*基于交易的序列推荐*和*基于交互的序列推荐*。我们将在第三节全面讨论这些任务以及具体的基于DL的推荐模型。

2.3 相关模型

在本小节中，我们首先回顾了应用于顺序推荐的传统ML方法，并简要地讨论了它们的优点和缺点。其次，我们总结了用于顺序推荐的相关DL技术，并阐述了它们如何克服传统方法中涉及的问题。

2.3.1 传统方法。顺序推荐的传统流行方法包括频繁模式挖掘、K-近邻、马尔科夫链、矩阵分解和强化学习[77]。他们一般采用矩阵分解法来解决用户在不同序列中的长期偏好，同时使用一阶马尔可夫链来捕捉用户在一个序列中的短期兴趣[31]。我们接下来介绍传统的方法以及顺序推荐的代表性算法。

频繁模式挖掘。我们知道，关联规则[64]努力使用频繁模式挖掘来挖掘具有足够支持和信心的频繁模式。在顺序推荐中，模式指的是在一个序列中经常共同出现的项目集合，然后被部署来进行推荐。尽管这些方法很容易实现，而且对用户来说也比较容易理解，但它们存在着可扩展性有限的问题，因为为推荐而匹配模式是非常严格和耗时的。

此外，确定合适的支持度和置信度阈值也是一个挑战，低的最小支持度或置信度值会导致识别出太多的模式，而大的

值将只是挖掘出频率很高的共同出现的项目, 从而导致只有少数项目可以被推荐或少数用户可以得到有效的推荐。

K-最近的邻居 (KNN)。它包括基于项目的KNN和基于会话的KNN, 用于顺序推荐。基于项目的KNN[21, 57]只考虑给定会话中的最后一个行为, 并推荐与其行为对象(项目)最相似的项目, 其中的相似性通常是通过余弦相似度或其他高级测量方法计算的[97]。相比之下, 基于会话的KNN[42, 51, 57]将整个现有会话与所有过去的会话进行比较, 通过项目空间的二进制向量上使用贾卡德指数或余弦相似度计算相似性来推荐项目。KNN方法可以产生高度可解释的推荐。此外, 由于相似性可以预先计算, 基于KNN的推荐系统可以迅速产生推荐。然而, 这类算法通常没有考虑到项目之间的顺序依存关系。

马尔可夫链 (MC)。在顺序推荐中, 马尔可夫模型假设未来的用户行为只取决于最后或最后几个行为。例如, [30]仅仅考虑了一阶马尔可夫链的最后一个行为, 而[29, 31]则采用了高阶马尔可夫链, 它考虑了与更多先前行为的依赖关系。只考虑最后一个行为或几个行为, 使得基于MC的模型无法利用相对较长序列的行为之间的依赖关系, 从而无法捕捉更复杂场景的复杂动态。此外, 它们还可能受到数据稀缺性问题的影响。

基于因子化的方法。矩阵分解 (MF) 试图将用户-项目交互矩阵分解为两个低秩矩阵。例如, BPR-MF[82]通过随机梯度下降 (SGD) 优化成对排名的目标函数。Twardowski[108]提出了一个基于MF的顺序推荐系统 (因子化机器[84]的简化版本), 其中只考虑会话和候选项目之间的互动来生成推荐。FPMC[83]是下一篮子推荐的代表性基线, 它将MF与一阶MC整合在一起。FISM[44]对项目-项目矩阵进行矩阵分解, 因此不需要学习明确的用户表示。在FISM的基础上, FOSSIL[31]通过结合基于相似性的方法和高阶马尔可夫链来处理顺序推荐任务。与传统的MC方法和FPMC相比, 它在稀疏数据集上的表现更好。基于MF的方法的主要缺点在于。1) 它们中的大多数只考虑潜在因素之间的低阶互动 (即一阶和二阶), 而忽略了可能的高阶互动; 2) 除了少数考虑时间信息的算法 (如TimeSVD++[47]) 外, 它们通常忽略了一个会话内和不同会话之间行为的时间相关性。

强化学习 (RL)。强化学习方法的本质是更新建议

根据用户和推荐系统之间的相互作用。当系统向用户推荐一个项目时, 如果用户对该项目表示兴趣 (通过点击或查看等行为), 就会得到一个正的奖励。它通常被表述为一个马尔科夫决策过程 (MDP), 目标是在一组互动中实现累积奖励的最大化[90, 151]。通过RL框架, 顺序推荐系统可以动态地适应用户 (不断变化的) 偏好。然而, 与基于DL的方法类似, 这种工作也缺乏可解释性。此外, 更重要的是, 在学术界很少有合适的平台或资源来开发和测试基于RL的方法。

2.3.2 深度学习技术。在本小节中, 我们总结了文献中顺序推荐中所采用的DL模型 (如RNN和CNN)。

循环神经网络 (RNNs)。在自然语言处理 (NLP) 领域, RNNs在序列建模中的有效性已经被广泛证明。在顺序

在推荐中，基于RNN的模型在基于DL的模型中占多数[17]。与传统模型相比，基于RNN的顺序推荐模型可以很好地捕捉到一个会话中或不同会话中的项目之间的依赖关系。顺序推荐的RNN的主要局限性是，在较长的序列中建立依赖关系的模型相对困难（尽管可以通过其他技术来缓解），而且随着序列长度的增加，训练的成本也很高。

卷积神经网络（CNN）。CNN通常应用于处理时间序列数据（如信号）和图像数据，其典型结构包括卷积层、池化层和前馈全连接层。它适合于捕捉跨局部信息的依赖关系（例如，图像中某一部位的像素之间的相关性或一句话中几个相邻的词之间的依赖关系）。在顺序推荐中，基于CNN的模型可以很好地捕捉会话中的局部特征，也可以在输入层中考虑到时间信息[105, 107]。

多层感知器（MLPs）。MLPs指的是具有多个隐藏层的前馈神经网络，因此可以通过非线性激活函数（如tanh和ReLU）很好地学习输入和输出之间的非线性关系。因此，基于MLP的顺序推荐模型有望很好地捕捉用户行为之间的复杂和非线性关系[128]。

注意机制。深度学习中的注意力机制是由人类的视觉注意力（倾向于被目标物体中更重要的部分所吸引）而来。它起源于Bahdanau等人的工作[4]，提出了神经机器翻译任务中的注意力机制，专注于建模输入句子中不同部分对输出词的重要性。在该工作的基础上，*香草注意力*是通过应用该工作作为RNN的解码器而提出的，并在顺序推荐中得到了广泛的应用[53]。另一方面，*自我注意机制*（起源于谷歌2017年的神经机器翻译的转化器[110]）也被部署在顺序推荐中。与vanilla attention相比，它不包括RNN结构，但在推荐系统中的表现比基于RNN的模型好很多[146]。

图形神经网络（GNN）。GNN[154]可以从图结构中集体汇总信息。由于它在许多应用中的有效性和优越性能，它在推荐系统中也获得了越来越多的关注。例如，Wu等人[131]首次将GNN用于基于会话的推荐，通过捕捉序列中项目之间更复杂的关系，每个会话被表示为使用注意力网络的长期偏好和短期兴趣在一个会话中的组成。




图8.一些最近的和有代表性的基于DL的顺序推荐模型。不同颜色表示不同的DL技术（灰色：MLP；橙色：RNN；黄色：CNN；蓝色：aNention机制；绿色：GNN）。

2.3.3 结语。与传统方法相比，基于DL的方法是近几年来更为活跃的研究领域。基于MC-和MF的模型假设用户的

下一个行为只与最近的几个行为有关, 而DL方法利用更长的序列进行预测[119], 因为它们能够有效地学习整个序列的主题。因此, 它们通常比传统模型获得更好的性能(就准确性测量而言)。同时, DL方法对稀疏的数据更加稳健, 能够适应不同长度的输入序列。有代表性的基于DL的顺序推荐算法见图8, 在接下来的章节中将详细介绍这些算法。

基于DL的顺序推荐方法的主要问题包括。1) 它们对生成的推荐结果缺乏可解释性。此外, 也很难校准推荐模型有效的原因, 从而对不同的场景产生稳健的基于DL的模型; 2) 一般来说, 优化是极具挑战性的, 对于复杂的网络需要更多的训练数据。

3 顺序推荐算法

在本节中, 为了弄清顺序推荐任务是否已经被充分探索, 我们从三个任务(第2.2节)的角度对顺序推荐算法进行分类: *基于经验的顺序推荐*、*基于交易的顺序推荐*和*基于交互的顺序推荐*。

3.1 基于经验的顺序推荐

正如我们所介绍的, 在基于经验的行为序列中, 用户以不同的行为类型与同一物品进行交互。基于经验的序列推荐的目标是预测用户将在该物品上实施的下一个行为类型, 因此它也被称为*多行为推荐*。因此, 我们首先探讨了关于多行为推荐的研究, 然后提出了基于DL的模型, 在顺序推荐中利用多行为信息。

3.1.1 用于多行为推荐的常规模型。Ajit et al.[91]首先提出了一个集体矩阵分解模型(CMF), 通过在矩阵间共享项目方潜在矩阵(项目嵌入)来同时分解多个用户-项目的行动矩阵(以不同的行为类型而言)。其他研究[48, 152]扩展了CMF来处理不同的用户行为(如社会关系)。此外, 也有一些模型用贝叶斯学习解决多行为推荐。例如, Loni等人[62]提出了多渠道的BPR来适应不同行为类型的采样规则。Qiu等人[76]通过考虑多种行为类型的共同发生, 进一步提出了一种自适应的BPR采样方法。Guo等人[28]旨在通过基于项目-项目相似性(由多种行为类型计算), 将未观察到的项目作为阳性项目进行抽样, 从而解决数据稀少的问题。Ding等人[23]开发了一个基于边际的学习框架来模拟购买、查看和非查看行为之间的配对排名关系。

3.1.2 基于DL的多行为推荐。DL技术也被应用于多行为推荐。例如, NMTR[26]被提出来解决传统的多行为推荐模型的一些代表性问题, 例如, 缺乏行为特征、不合理的嵌入学习和无法对复杂的交互关系进行建模。为了捕捉行为类型之间的顺序关系, NMTR[26]通过考虑实践中不同行为之间的顺序依赖关系, 对不同行为类型进行级联预测⁶, 从而将异质行为问题转化为我们所定义的基于经验的顺序推荐问题。需要注意的是

⁶ 例如, 在电子商务中, 同一物品的搜索、点击和购买操作通常是按顺序排列的。

这种级联预测，可以看作是在学习目标行为的推荐模型之前对其他行为类型的嵌入层进行预训练，它只考虑了目标行为和以前的行为之间的联系，而忽略了目标行为和后续行为之间的联系。因此，它并没有充分探索各种行为类型之间的关系。在这种观点下，多任务学习（MTL）可以通过提供一个同时预测多个任务的范式来解决这个问题，同时也可以利用不同任务之间的相似性和差异性。在[26]中提出的MTL模型的性能通常比使用顺序训练的模型要好。此外，Xia等人[133]提出了一个带有LSTM的多任务模型，通过预测用户在特定时间的阶段和决定，在一套预先定义的启发式规则的帮助下，明确地模拟用户的购买决策过程，从而获得更准确的推荐结果。

3.2 基于交易的顺序推荐

在基于交易的顺序推荐中，只有单一的行为类型（与交易有关，例如购买），推荐模型一般考虑不同对象（项目）之间的顺序依赖关系以及用户的偏好。由于有大量的基于DL的模型用于这一任务，我们进一步总结了现有模型所采用的具体DL技术。

3.2.1 基于RNN的模型。在基于交易的顺序推荐任务中，RNN结构已经得到了很好的利用，我们从以下几个方面总结了基于RNN的方法。

(1) GRU4Rec相关模型。Hidasi等人[34]提出了一个基于GRU的RNN模型用于序列推荐（即GRU4Rec），这是第一个将RNN应用于序列推荐的模型，并且不考虑用户的身份（即匿名用户）。在其基础上，提出了一系列改进的模型[12, 33, 103]，这些模型也使用RNN架构对行为序列进行建模。GRU4Rec的架构如图9所示。如[34]所介绍的，GRU4Rec的输入是一个会话（行为序列），它可以是一个单一的项目，也可以是一个会话中出现的项目集。它使用单次编码来表示当前的项目，或者使用加权的编码总和来表示项目集。该模型的核心是GRU层，每层的输出是下一层的输入，但每层也可以连接到网络中更深的非相邻的GRU层。在最后一个GRU层和输出层之间加入前馈层。输出是每个候选项目在下一个行为中出现的概率。




图9.GRU4Rec的结构。

GRU4Rec采用会话并行小批和基于流行度的负抽样进行训练。使用会话并行小批的原因是为了形成长度相同的会话，同时

实际会话的长度可以有很大变化。另一方面, 如果简单地把一个会话分解成不同的部分, 强迫它们变成相等的长度, 我们就不能很好地模拟行为序列, 不能捕捉到一个会话是如何随时间演变的[34]。

延伸的研究致力于从模型训练和设计更先进的模型结构的角度来提高模型的性能, 以更好地学习项目信息。例如, 为了**促进训练**, [103]应用**数据增量**来加强GRU4Rec的训练。[12]考虑了**停留时间**来修改小批量的生成, 经过验证, 这大大提高了性能。另一方面, 基于流行度的抽样存在这样的问题: 当所有的候选项目都被排在流行度以上时, 模型的学习就会变慢, 这对于长尾项目的推荐来说可能是一个比较严重的问题。因此, [33]提出了GRU4Rec中的负向抽样的**附加抽样**(均匀抽样和流行抽样的结合), 可以极大地提高性能。

为了**更好地对物品信息进行建模**, [35]考虑了除ID之外的其他物品信息(如文本描述和图片), 以提高预测性能。具体来说, 他们引入了一些平行RNN(p-RNN)架构, 根据点击行为和被点击物品的其他特征(如图片和文字描述)对会话进行建模。此外, 他们特别为p-RNN提出了其他但更合适的训练策略:**同步训练**、**交替训练**、**残差训练**和**交错训练**。在同步训练(基线)中, 每个子网的每个参数都是同时训练的。在交替训练中, 子网在每个历时中以交替的方式进行训练。在残差训练中, 子网是通过之前训练的子网集合的残差逐一训练的, 而交错训练是每个小批的交替训练。此外, [42]使用**切换**、**级联**和**加权混合**的方法将基于会话的KNNs与GRU4Rec相结合。

(2) 有了用户代表。也有一些研究旨在更好地模拟用户的偏好。例如, [149]提出了一个基于RNN的框架来预测赞助商搜索中的点击率(CTR), 该框架考虑了点击停留时间的影响, 假设用户在广告页面停留的时间越长, 广告对用户的吸引力就越大。总共考虑了三类特征: 广告特征(广告ID、位置和查询文本)、用户特征(用户ID、用户的查询)和顺序特征(时间间隔、停留时间和点击顺序)。[94]将用户行为序列中的项目进行一次编码, 作为基于GRU的RNN的输入, 学习用户的历史嵌入。*RRN*[129]是第一个试图捕捉用户和项目表现的动态的递归推荐网络。[11]通过设计一个时间变化的邻域风格解释方案进一步提高了RRN的可解释性, 该方案共同优化了预测准确性和顺序推荐的可解释性。

考虑到简单地将用户的历史信息嵌入到一个单一的向量中可能会失去用户的历史序列和长期偏好之间的每个项目或特征级别的相关信息, Chen等人[15]因此提出了一个用于序列推荐的记忆增强的神经网络。该模型通过利用外部记忆矩阵明确地存储和更新每个用户的历史信息。Huang等人[40]进一步改进了[15], 采用了一个单独的GRU组件来捕捉顺序依赖性, 并纳入了知识库(KB)信息以更好地学习属性(特征)级的用户偏好。为了更好地对每个用户的终身顺序模式进行建模, Ren等人[80]提出了一个层次化的周期性记忆网络(*HPMN*)来捕捉多尺度的顺序模式, 其中周期性记忆更新机制被设计用来避免意外的知识漂移, 层次化的记忆槽被用来处理不同的更新期。

HRNN[78]⁷使用GRU分别对用户和会话进行建模。会话级的GRU考虑用户在一个会话中的活动,从而产生建议,而用户级的GRU则对用户在不同会话中的偏好演变进行建模。考虑到不同用户的会话长度是不同的,它部署了用户平行小批量训练,这是从GRU4Rec的会话平行小批量中扩展出来的。Donkers等人[24]进一步提出了一个基于用户的GRU框架(包括基于用户的线性GRU、基于用户的矫正线性GRU和基于用户的注意力GRU),以整合用户信息,给出更好的用户表示。*HierTCN*[138]也涉及到一个基于GRU的高层模型,以汇总用户在不同时段不断变化的长期偏好,而*SDM*[65]特别设计了一个门控融合模块来有效整合用户的短期和长期偏好。

(3) 语境感知的顺序推荐。以前的大多数模型都忽略了实词场景中大量的语境信息。在这种观点下,[59]总结了两类语境:*输入语境*和*转换语境*。输入语境指的是用户进行行为的语境,如位置、时间和天气,而过渡语境指的是历史序列中两个相邻输入元素之间的转换(如相邻行为之间的时间间隔)。它进一步设计了情境感知的循环神经网络(*CA-RNN*)来同时模拟序列和情境信息。此外,[96]提出了*ARNN*来考虑用户侧的环境,如年龄、性别和位置。具体来说,*ARNN*使用基于产品的神经网络提取高阶的用户情境偏好,它能够与任何现有的基于RNN的顺序推荐模型结合。

(4) 其他模型。除了上述三类,文献中还有其他基于RNN的模型(如*DREAM*[139])用于基于交易的顺序推荐。例如,[22]将RNN用于协同过滤任务,并在RNN模型中考虑了两种不同的目标函数:分类交叉熵(*CCE*)和*Hinge*,其中*CCE*已被广泛用于语言建模,而*Hinge*则是从SVM的目标函数中扩展出来的。[85]部署了一个多层GRU网络,从会话间和会话内两个层面捕捉顺序依赖和用户兴趣。鉴于现有的研究假设用户在会话中只有一个隐含的目的,Wang等人[122]提出了一个混合通道目的路由网络(*MCPRNs*)来捕捉用户在会话中可能的多重目的(一个通道意味着一个潜在的目的)。*MCPRNs*由一个目的路由器(*PRN*)和一个具有特定目的递归单元的多通道递归框架组成。

3.2.2 基于CNN的模型。由于网络结构和相对昂贵的计算成本,RNN模型在对相对较短的序列进行建模时受到限制,这一点可以通过CNN模型[89]得到部分缓解。例如,*3D-CNN*[107]设计了一个嵌入矩阵,将物品ID、名称和类别的嵌入连接起来。*Caser*[105]将*L*以前物品的嵌入矩阵视为“图像”,因此使用水平卷积层和垂直卷积层来分别捕获点级和联合级的顺序模式。利用卷积,对相关跳过行为的感知成为可能。它还通过用户嵌入来捕捉用户的长期偏好。*CNN-Rec*[38]的网络结构在用户嵌入和水平卷积方面与*Caser*高度相似,但它没有部署垂直卷积。*NextItNet*[142]是一个生成性的CNN模型,具有用于顺序推荐的剩余块结构。它能够捕捉到长期和短期的项目依赖性。*GRec*

[141]进一步扩展了*NextItNet*,利用基于间隙填充的编码器-解码器框架和掩码卷积操作来共同考虑过去和未来的上下文(数据),而不存在数据泄露问题。在*HierTCN*[138]中,一个用时间卷积法实现的底层模型

⁷ github.com/mquad/hgru4rec.

网络 (TCN) 将从GRU模块学到的长期用户偏好和会话中的短期用户偏好统一起来, 生成最终推荐。

3.2.3 基于注意力的模型。注意力机制在很大程度上被应用于顺序推荐, 并且能够根据用户的历史经验识别出与用户更“相关”的项目。我们根据所部署的注意机制类型来总结这些模型: *香草式注意*和*自我注意*(见2.3.2节)。

(1) 香草注意机制。*NARM*⁸ [53] 是一个用于基于交易的顺序推荐的编码器-解码器框架。在本地编码器中, RNN与vanilla注意力相结合

以捕捉用户在当前序列中的主要目的(或兴趣)。有了注意力机制, *NARM*能够消除来自非预期行为的噪音, 例如意外的(未趋向的)点击。[120]应用香草的注意力机制对序列中的每个项目进行加权, 以减少非故意互动的负面影响。Liu等人[61]提出了一个短期注意力/记忆优先级模型, 该模型使用香草式注意力来计算序列中项目的注意力分数, 以及之前项目和序列中最近项目之间的注意力相关性。Ren等人[81]考虑了重复消费的问题, 因此提出了*RepeatNet*, 它评估了重复模式和探索模式的推荐, 这两种模式分别指的是用户历史上的旧项目和新项目。

[86]将vanilla注意力与Bi-GRU网络结合起来, 为用户的短期兴趣建模, 用于音乐推荐。[5]提出了一个统一的属性感知神经注意力模型(*ANAM*), 该模型在特征层面上应用了vanilla注意力机制。为了更好地捕捉用户的短期偏好, Yu等人[140]设计了一个多阶注意力网络, 该网络由两个k层残差网络实例化, 分别模拟个人层面和联盟层面的项目依赖。

(2) 自我注意机制。自我关注机制在顺序推荐中也获得了越来越多的关注。例如, Zhang等人[146]利用自我注意机制从用户的历史交互中推断出项目与项目的关系。通过自我关注, 它能够估计用户交互轨迹中每个项目的权重, 以学习用户短期意向的更准确的表述, 同时它使用一个度量学习框架来学习用户的长期兴趣。在*SDM*[65]中, 加入了一个多头的自我注意模块来捕捉用户在一个会话中的多种兴趣(即短期偏好), 而用户的长期偏好也通过注意力和基于各种类型的侧面信息的密集全连接网络进行编码, 例如, 用户历史交易中的物品ID、第一层类别、叶子类别、品牌和商店。同样, *SASRec*[45]采用了一个自我注意层来平衡短期意图和长期偏好, 并试图从用户的历史行为序列中识别与下一个行为相关的物品。

BERT4Rec[99]是*SASRec*的改进版, 它引入了转置器结构。

顺序推荐, 并使用Cloze任务训练双向模型来模拟顺序数据。*TiSASRec*[54]通过考虑序列中项目之间的时间间隔, 进一步改进了*SASRec*。具体来说, 它根据历史序列中每两个项目之间的时间间隔信息, 为每个用户建立项目间的关系矩阵。此外, 为了克服基于RNN的顺序推荐系统的缺点, 如不支持并行性和只对连续项目之间的单向转换进行建模, *SANSR*

[100]结合了转置器框架[110]来加快训练过程, 并学习会话中项目之间的关系, 而不考虑距离和方向。

我们知道, 以前关于顺序推荐的研究大多集中在推荐的准确性上, 而忽略了推荐结果的多样性, 这也是有效推荐的一个相当重要的衡量标准。关于这个问题, Chen等人[14]说

⁸ github.com/lijingsdu/sessionRec_NARM。

提出了一种意图感知的顺序推荐算法，该算法使用自我注意机制来模拟用户在特定会话中的多种意图。

3.2.4 其他模型。还有一些其他的DL结构（例如MLP[118]、GNN[126]和自动编码器）被用于顺序推荐。例如，*NN-rec*[112]是第一个考虑将神经网络用于下一篮子推荐的工作，其灵感来自NLPM[9]。Wu等人[131]将GNN用于基于会话的推荐，以捕捉项目之间的复杂转换。在这个模型中，每个会话被建模为一个有向图，并由一个门控图神经网络进行，以获得会话表示（本地会话嵌入和全局会话嵌入）。*GACOforRec*[144]利用图卷积神经网络来学习会话中的项目顺序以及网络中的空间性来处理用户的短期意图，同时它设计了ConvLSTM来捕获用户的长期偏好。此外，考虑到不同的行为可能有不同的影响，它提出了一对新的注意力机制，考虑到图卷积网络中不同的传播距离来获得不同的权重。*UGrec*[117]将用户和物品的交互建模为图网络，从用户的购买历史中定义了连续的推荐路径，并使用关注机制进一步聚合了不同的路径。最后，在图嵌入中设计了一个特别设计的翻译学习目标函数用于模型学习和推理。

Sachdeva等人[87]探讨了变异自动编码器对用户的偏好进行建模。

通过他/她的历史序列，将潜在变量与时间依赖性结合起来进行偏好建模。Ma et al.[66]专门设计了一个带有BPR的分层门控网络（HGN）来捕捉长期和短期用户的偏好。

3.3 基于互动的顺序推荐

与上述两个任务相比，基于互动的任务要复杂得多，因为每个行为序列都由不同的行为类型和不同的行为对象组成。因此，推荐模型应分别捕捉不同行为、不同项目以及行为和项目之间的顺序依赖关系。接下来，我们根据所部署的DL技术对相关模型进行总结。

3.3.1 基于RNN的模型。在这项任务中，基于RNN的模型仍然占据了大多数角色[63]。例如，[108]提出了一个基于RNN的模型，没有明确地学习用户表示。考虑到预测下一个预计出现的目标行为类型的任务，Le等人提出了一个基于RNN的模型。

[49]首先根据目标行为类型将一个会话分为目标序列和支持序列。其基本思想是，目标行为类型（如购买）包含了预测任务最有效的信息，其余的行为（如点击）因此可以作为支持序列被利用，以促进目标行为类型的下一个项目预测任务。此外，为了更好地模拟不同行为类型之间的依赖关系，一些研究还会假设不同类型的行为之间存在级联关系（如3.1.2节）（即不同行为类型是按顺序排列的）。例如，Li等人[56]提出了一个由两个主要部分组成的模型：*神经项目嵌入*[7]和*判别性行为学习*。对于行为学习，它利用所有类型的行为（例如，点击、购买和收集）来捕捉用户目前的消费动机。同时，它从用户的历史经验中选择与购买有关的行为（如购买、收集和添加到购物车）来模拟用户的潜在长期偏好。考虑到RNN不能很好地处理用户在序列中的短期意图，而对数线性模型（LBL）不能捕捉用户的长期偏好，Liu等人[60]将RNN与LBL相结合，构建了两个模型（*RLBL*和*TA-RLBL*），用于建模多行为序列。*TA-RLBL*是*RLBL*[60]的一个扩展，它考虑了输入行为对象和输入行为对象之间的连续时间差信息。

从而进一步提高RLBL的性能。[93]通过修改RNN的结构，将背景信息（如行为类型）考虑在内。

3.3.2 *其他模型*。还有一些其他的DL技术应用于基于交互的顺序推荐，包括注意力机制、MLPs和基于图的模型。例如，[153]提出了 $ATRank^9$ ，它同时采用了*自我注意*和*香草注意*机制。考虑到行为的异质性， $ATRank$ 通过自我注意来模拟行为之间的影响，而它使用香草注意来模拟不同行为对推荐任务的影响。 $CSAN$ [41]是 $ATRank$ 的改进版，它还考虑了行为类型的侧面信息和多义性。Wu等人[128]提出了一个深度列表网排名框架（基于MLP），共同考虑用户的点击和观点。Ma等人[67]提出了一个用于新闻推荐的基于图的广义认知网络（ $G-BBAN$ ），它考虑了多种用户行为、行为序列表示和用户表示。

表1.关于顺序推荐任务和DL模型的代表性算法的类别。

任务	DL模型	论文
基于经验的	MLP	[26]
	矩阵 (RNN	[133]
基于交易的		[12, 15, 24, 34, 59, 78, 96, 103, 139]
	矩阵 (RNN	[14, 22, 33, 35, 40, 42, 85, 100, 149]
		[11, 65, 80, 94, 129, 130, 138]
	有线电视新闻网	[38, 105, 107, 138, 141, 142]
	MLP	[112, 118]
	注意机制	[5, 45, 53, 61, 81, 86, 120, 137]
		[14, 54, 65, 99, 130, 140, 146]
	大陆新闻网	[117, 126, 131, 144]
基于互动的	其他网络	[66, 87]
	RNN	[49, 56, 60, 63, 93, 108]
	MLP	[128]
	注意力机制	[41, 63, 153]
	GNN	[67]

3.4 结论性意见

在本节中，我们介绍了三种顺序推荐任务的代表性算法。我们在表中列出了任务和DL技术方面的代表性算法。

1.综上所述，RNNs和注意力机制在交易和基于交互的顺序推荐任务中都得到了很大的探索，而其他DL模型（如GNN和生成模型）的有效性还需要进一步研究。此外，现有的模型也存在一些问题，特别是对于复杂的基于交互的顺序推荐：（1）行为类型和行为2元组（ $\square\square, \square\square$ ）中的项目大多被同等对待。例如， $ATRank$ [153]和 $CSAN$ [41]对项目和相应的行为类型采用相同的注意分数；（2）不同的行为类型没有被成功区分。例如，[108]使用相同的网络对不同的行为类型进行建模，假设不同的行为类型具有相似的模式；（3）序列中的行为之间的关联性

⁹ github.com/jinze1994/ATRank。

是很容易被忽略的。例如，[128]使用池化操作来模拟序列中的多类型行为。鉴于这些问题，为了更有效的顺序推荐，特别是基于交互的顺序推荐任务，需要更先进的方法。在接下来的两节中，我们将进一步总结和评估可能影响基于DL的模型在推荐准确性方面表现的因素，这些因素有望更好地指导未来的研究。

4 对基于DL的模型的影响因素




图10.基于DL的模型的影响因素。

图10显示了一个顺序推荐系统的训练和测试过程。在训练中，输入包括原始数据和标签信息，然后被送入数据处理模块，主要包括特征提取和数据增强。特征提取是指将原始数据转换为结构化数据，而数据增强通常用于处理数据稀少和冷启动问题，特别是在基于DL的模型中。第三，根据处理过的数据对模型进行训练和评估，模型结构或训练方法（如学习率、损失函数）可以根据评估结果以迭代的方式更新，直到达到满意的性能。在测试中，数据处理模块只包括特征提取，然后用得到的训练好的模型来做推荐。

在全面的文献研究的基础上，我们确定了一些有代表性的因素（在图10和表2的灰框中列出），这些因素可能影响基于DL的模型在推荐准确性方面的表现。这些因素的细节将在随后讨论。

4.1 输入模块

侧面信息和行为类型是输入模块中基于DL的模型的关键因素。

4.1.1 侧面信息。侧面信息已被公认为是促进推荐性能的有效手段[101]。它指的是关于物品的信息（除ID外），例如，类别、图像、文本描述和评论，或者与交易（行为）相关的信息，如停留时间。在基于DL的协同过滤系统中[6, 18, 73, 79, 145]，以及在一些基于DL的顺序推荐系统中[35, 41]，关于物品的文本和图像信息已被广泛探索。例如，p-RNN[35]使用一个并行的RNN框架来处理项目ID、图像和文本。具体来说，第一个并行架构在每种信息的基础上分别训练一个GRU网络（即子网）来表示物品。该模型将子网的隐藏层串联起来并产生输出。第二个架构有一个共享的隐藏状态到输出的权重矩阵。隐藏状态的加权和被用来产生输出，而不是由单独的子网计算。在第三个结构中，称为平行交互，物品特征子网的隐藏状态与ID子网的隐藏状态以元素的方式相乘，然后生成最终结果。CSAN[41]利用

表2.对基于DL的顺序推荐系统的影响因素。

模块	因素	方法	论文
输入	侧面信息	利用图像/文字	[35, 41]
		利用停留时间	[12, 20, 149]
	行为类型	简单的行为嵌入	[153]
		将会议分成几组 用于不同的目的	[49, 56]
	重复消费	考虑重复行为	[39, 81, 111]
数据处理	嵌入设计	项目嵌入	[27]
		w-item2vec	[56]
		会话嵌入	[128]
	数据扩增		[103, 107]
模型结构	纳入 注意力机制	唯一的注意机制	[5, 41, 146, 153]
		加入香草 注意力机制 与其他DL方法	[45, 53, 61, 120]
	与 传统的 方法	KNN	[42]
		度量学习	[146]
	加入 显式 用户代表	用户嵌入模型	[105, 118]
		用户递归模型	[11, 15, 24, 56, 78, 80, 129]
模型培训	负面采样	统一	[33, 34]
		基于人气	[33, 34]
		其他	[33]
		样本量	[33]
	小批量创建	届时平行	[34]
		项目提升	[12]
		用户并列	[78]
	损失函数	TOP1	[34]
		TOP1-max & BPR-max	[33]
		CCE & Hinge	[22]

word2vec和CNN分别学习文本和图像 的表示。以前的模型已经证明，像物品图像和文本这样的侧面信息可以缓解数据的稀疏性[35, 55, 116]和冷启动[41, 115, 127, 153]问题。

另一方面，像*停留时间*这样的侧面信息部分地暗示了用户对不同项目的兴趣程度。例如，当一个用户为一个项目浏览网页时，他/她停留的时间越长，我们可以推断出他/她的兴趣越大。Bogina等人[12]根据停留时间在训练中生成小批量的项目提升。特别是，假设预设的停留时间阈值为 t_d 秒，如果一个会话中某个对象*i*的停留时间在以下范围内

的 $[2\Box, 3\Box]$ ，那么这个会话的平行小批就会包含两个与 \Box 有关的重复行为，也就是说，会话中 \Box 的存在会增加。这种策略(被称为*项目提升*)可以被认为是根据相应的停留时间来重新衡量行为对象的重要性。Zhang等人[149]将停留时间作为一个序列特征，并将其与其他特征(如查询文本)相连接。同样，Dallmann等人[20]通过增加用户停留时间提出了对现有RNN方法的扩展。[12]中的实验表明，将停留时间与GRU4Rec[34]结合在一起会有很大的改进(MRR@20上高达153.1%)。

4.1.2 行为类型。在顺序推荐中，用户行为序列中的行为通常是异质的和多义的[41, 153]，不同的行为类型意味着用户的不同意图。例如，购买行为比点击行为更能说明用户对某个物品的偏好。因此，区别对待不同的行为类型至关重要[26, 49, 108, 153]。例如，CBS[49]在行为类型方面将一个序列分为目标序列和支持序列，其中目标序列与具有最有效的预测信息的行为类型(如购买)有关。同样，BINN[56]利用所有的行为类型(如点击、购买和收藏)来捕捉用户当前的兴趣，而只用购买相关的信息(如购买、添加到购物车和收藏)来模拟用户的长期偏好。[153]学习每种行为类型的表示方法，然后将它们与相应的项目嵌入向量连接起来。实验普遍支持购买行为可以更准确地捕捉用户的长期偏好，而其他行为类型可以促进短期兴趣的学习[26, 49, 108, 153]。

4.1.3 重复消费。重复消费是指一个项目在用户的历史序列中反复出现，这在顺序推荐中大多被忽略。Anderson等人[2]在七个真实的数据集上研究了重复消费的动力，发现经常性是重复消费的最强预测因素。Bhagat等人[10]提出了四种用于重复购买推荐的模型(即重复顾客概率模型、集合时间分布模型、Poisson-Gamma模型和修正的Poisson-Gamma模型)。[113]进一步将协同过滤和Hawkes Process结合起来，建立了一个整体的推荐模型，重复消费的特定物品时间动态被捕捉到。对于顺序推荐，Wan等人[111]使用*忠诚度*因子对重复消费进行建模，可以进一步提升下一篮子推荐的性能。Ren等人[81]¹⁰也考虑了这个问题，他们的结果证实，在DL网络设计中考虑重复消费模式可以提高推荐性能。最近的研究[39]刚刚指出，基于RNN的模型可能不能很好地捕捉下一篮子推荐的重复行为，因此提出了一个基于KNN的模型来捕捉下一篮子推荐的重复消费。

应该指出的是，尽管侧面信息和行为类型可以大大改善模型的性能，他们的收集可能是不可行的或耗费成本的。

4.2 数据处理

特征提取方法的适当设计(即*嵌入设计*)和*数据增强*

在现有的基于DL的模型中，生成更多训练数据的方法已被验证为有效。

4.2.1 嵌入设计。在顺序推荐中，嵌入方法被用来表示关于一个物品、一个用户或一个会话的信息。例如，Greenstein等人[27]采用单词嵌入方法GloVe[75]和Word2Vec[70](CBOW)用于电子商务应用中的*物品嵌入*。Li等人[56]进一步提出了w-item2vec(受到item2vec[7]的启发)

¹⁰ github.com/PengjieRen/RepeatNet.

在Skip-gram模型的基础上, 从而形成了项目的统一表示。Wu等人

[128]通过考虑不同的用户搜索行为(如点击和浏览)、目标项目嵌入和用户嵌入, 设计了一个用于预训练的会话嵌入, 以有一个全面的会话理解(即会话表示)。

4.2.2 数据扩增。在顺序推荐中, 在某些情况下, 可能没有新用户的用户资料或历史信息, 或者没有登录的用户, 也就是冷启动问题。因此, 数据增强成为一种重要的技术。例如, Tan et al. [103]提出了一种增强的方法, 如图11所示, 原始输入会话的前缀被视为新的训练序列。也就是说, 给定原始会话($\square_1, \square_2, \square_3, \square_4$), 我们可以产生3个训练序列。(\square_1, \square_2), ($\square_1, \square_2, \square_3$), ($\square_1, \square_2, \square_3, \square_4$), 而推荐算法预测每个训练序列的最后一项内容。通过这种方法, 在训练过程中反复利用一个会话, 证明在MRR@20上比GRU4Rec提高了14.7%[103]。此外, 为了防止过度拟合问题, 进一步采用了辍学方法[98](见图11, 带虚线的圆圈是每个序列中的辍学行为)。此外, 考虑到目标项目之后的项目也可能包含有价值的信息, 因此这些项目被视为特权信息[109], 以促进学习过程。

同样, 对于两种行为类型(即添加到购物车和点击), 3D-CNN[107]也使用了**数据增强**, 它将直到最后一个添加到购物车的项目的所有前缀作为每个包含至少一个添加到购物车项目的训练序列。此外, 它使用**右键填充**或**简单的删除**方法来保持所有序列的相同长度。

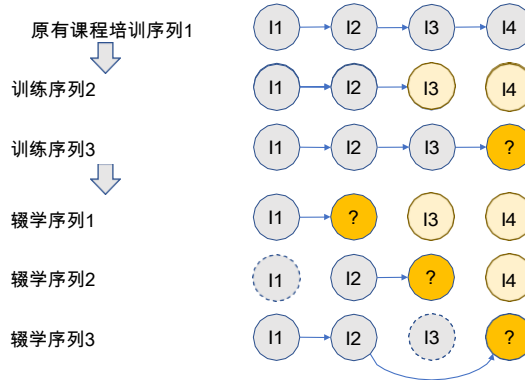


图11.数据扩增。橙色的圆圈代表预测的项目; doNed圆圈代表在辍学方法中被删除的项目, 浅橙色的圆圈构成了特权信息。

4.3 模型结构

我们把以前基于DL的模型中改进模型结构的主要方法总结为: **纳入注意机制**, 与**传统模型相结合**, 以及**增加明确的用户表示**。

4.3.1 纳入AFention 机制。在第2.3.2节中, 我们讨论了主要有**香草式注意力**和**自我注意力**。总的来说, 我们可以将注意力机制与其他DL模型结合起来, 或者直接建立注意力模型来解决顺序推荐问题。对于第一个

NARM[53]、ATEM[120]和STAMP[61]将*虚无的注意力机制*与RNN或MLP结合起来，旨在捕捉用户在特定会话中的主要目的。实验证明，它们的性能分别比GRU4Rec高出25%、92%和30%。SASRec[45]将自我注意与前馈网络结合起来，对不同行为之间的相关性进行建模，与GRU4Rec和Caser[105]相比，在HR@10上可以分别提高47.7%和4.5%的推荐准确性。对于第二种情况，例如，AttRec[146]只是部署了一个自我注意机制来捕捉用户的短期兴趣，其性能在HR@50上比Caser高出8.5%。ATRank[153]和CSAN[41]将自我注意和香草注意结合起来进行顺序推荐。注意力机制可以被进一步用来捕获项目的属性级重要性水平，以模拟用户的兴趣。例如，ANAM[5]应用注意力机制来跟踪用户对物品及其属性的偏好。

总而言之，以前的研究表明，纳入注意力机制可以改善基于DL的模型的推荐，而大部分只使用自我注意力机制的模型可以比一些没有注意力机制的基于DL的模型有更好的表现。

4.3.2 与传统方法相结合。基于DL的模型也可以与传统方法相结合，以提高其在连续推荐任务中的性能。比如说。

[42]将基于会话的KNN与GRU4Rec[34]以三种不同的方式（即切换、级联和加权混合）结合起来，显示在某些应用中，最佳组合可以超过原始GRU4Rec 9.8%。AttRec[146]结合了自我注意（用于短期兴趣学习）和度量学习（用于长期偏好建模），其性能在HR@50上超过Caser[105]8.5%。

4.3.3 增加明确的用户表征。考虑到可以识别用户ID的应用场景，我们可以设计显式学习用户表征的方法，也就是说，用户的长期偏好可以通过*用户嵌入模型*或*用户递归模型*很好地建模。

用户嵌入模型。这类模型明确地通过嵌入方法学习用户表征[105, 118]，但不是像项目表征那样在一个循环过程中学习。它们可以促进顺序推荐模型的性能[105]。然而，这样的模型可能会受到冷启动用户问题的影响，因为用户的长期兴趣和很少的历史信息不能被很好地学习。另一个问题是，通过用户嵌入模型的用户表示是以一种相对静态的方式学习的，它不能捕捉到用户不断变化的动态偏好。在这种观点下，用户递归模型被认为是更有效的，它以一种递归的方式学习用户表征，如同项目表征学习一样。

用户递归模型。他们在基于DL的模型中把用户和物品的表征都作为递归成分，这样可以更好地捕捉用户不断变化的偏好，包括记忆增强的神经网络[15, 80]，基于RNN的模型[24, 56, 78]和递归神经网络

[11, 129]。例如，[24, 56, 78]使用RNN框架，从用户的历史行为序列中学习用户的长期兴趣。实验证明，考虑用户的长期兴趣对个性化推荐是非常有价值的，例如，HRNN[78]在某些场景下，通过明确的用户表示，比GRU4Rec高出3.5%。

总之，模型结构在顺序推荐中起着重要作用，更好的设计有助于更有效地捕捉项目和行为之间的顺序依赖，从而更好地理解用户的短期和长期偏好。

4.4 模型培训

精心设计的训练策略也能促进基于DL的顺序推荐模型的学习。通过全面的调查，我们总结了三种主要的策略：*负采样*、*小批量创建*和*损失函数*。

4.4.1 负面抽样。基于人气的抽样和统一抽样已被广泛用于推荐中。基于人气的抽样假设，一个项目越受欢迎，用户就越有可能知道它。也就是说，如果一个用户之前没有和它互动，那么这个用户就更有可能是它不喜欢它。[33]通过结合这两种抽样策略，进一步提出了一种新的抽样策略（称为**附加抽样**），它吸取了这两种策略在消极抽样中的优点，但又克服了其缺点。在附加抽样策略中，负面样本的选择概率与 supp_i^α 成正比，其中 supp_i 是项目*i*的支持度， α 是一个参数（ $0 \leq \alpha \leq 1$ ）。 $\alpha=0$ 和 $\alpha=1$ 的情况分别等同于均匀抽样和基于人气的抽样。实验结果表明，在某些情况下（如损失函数），额外的抽样可以超过基于人气的抽样和统一抽样方法。此外，**负样本的大小**也会影响顺序推荐模型的性能。

4.4.2 小批量创作。会话平行小批训练[34]的提出是为了适应不同长度的会话，并努力捕捉会话随时间变化的动态。特别是，会话首先按时间顺序排列。然后，第一个*X*会话的第一个事件（行为）（*X*是会话的数量）被用来形成第一个小批的输入（其期望输出是活动会话的第二个事件）。第二个小批处理是由*X*会话的第二个事件形成的，以此类推。如果任何一个*X*会话达到它的终点，*X*会话中的下一个可用会话被放在相应的位置上，继续形成小批处理。会话并行小批有两种变体：**项目提升**和**用户并行小批**。在项目提升中，一些项目可以在迷你批中重复使用，如停留时间[12]，而关于后一种变体，例如，HRNN[78]设计了用户平行迷你批（即，平行会话属于不同的用户）来模拟用户在不同会话中的偏好演变。

4.4.3 损失函数设计。损失函数也会大大影响模型的性能。在顺序推荐中，已经采用了相当多的损失函数，包括**TOP1-max**（TOP1的排名-最大值版本）、**BPR-max**（BPR的排名-最大值版本）、**CCE**（分类交叉熵）和**Hinge**。

TOP1是一个正负样本相对排名的正则化近似值。如公式2所示，它由两部分组成：第一部分倾向于惩罚正样本 \square 和任何负样本 \square （ $\square \square$ 是负样本的大小）之间的错误排名，第二部分被用作正则化。

$$\text{TOP1} \square = \frac{1}{\square \square} \sum_{\square \square=1}^{\square \square} \sigma(\square \square - r) + \sigma(r^2) \quad (2)$$

其中 $\sigma(\cdot)$ 是一个sigmoid函数， $\square \square$ 和 $\square \square$ 分别是样本 \square 和 \square 的排名分数。按照同样的符号，**BPR**（贝叶斯个性化排名）[82]被定义为。

$$\text{BPR} \square = \frac{1}{\square \square} \sum_{\square \square=1}^{\square \square} \log \sigma(\square \square - r) \quad (3)$$

对于基于DL的模型，TOP1和BPR损失函数可能存在梯度消失的问题（例如，在GRU4Rec[33]中）。在这种观点下，提出了Ranking-max损失函数系列[33]来解决这个问题，其中排名分数只与与目标样本最相关的负面样本进行比较，即具有最高排名分数的样本。因此，我们有**TOP1-max**和**BPR-max**，它们分别表述为公式4和5。它们可以分别被视为TOP1和BPR的加权版本。以前的研究验证了这一点

the two loss functions largely improve the performance of RNN-based sequential recommendation models [33].

$$\square \text{TOP1-max} = \sum_{\square=1}^{\square} \square \sigma(r_j - \square_i)^2 + \sigma(r_j) \quad (4)$$

其中 \square 是使用softmax函数对 \square 的归一化分数。

$$L_{\text{BPR-max}} = -\log \sum_{\square=1}^{\square} \sigma(r_i - r_j) \quad (5)$$

除了基于排名的损失函数外， CCE （分类交叉熵）和Hinge损失函数也被应用于顺序推荐中[22]。 CCE 定义为：

$$CCE(o, i) = -\log(\text{softmax}(o))_i \quad (6)$$

其中 o 是一个模型输出， i 是一个目标项目。由于softmax函数的存在， CCE 存在计算复杂性的问题。相反，Hinge将预测的结果与预先定义的阈值（例如0）进行比较。

$$\text{Hinge}(o, i) = \sum_{j \in C} \max(0, 1 - o_j) + \gamma \sum_{j \in F} \max(0, q) \quad (7)$$

其中， C 是包含项目 i 的推荐集合，而 F 是不包含 i 的推荐集合（即不良推荐）。 γ 是一个参数，用于平衡两部分错误（正确推荐与不正确推荐）的影响。通过Hinge loss，推荐任务被转化为一个二元分类问题，由推荐系统来决定一个项目是否应该被推荐。

5 关于影响因素的实证研究

在这里，我们在真实的数据集上进行实验¹¹，以展示影响因素对基于DL的模型在推荐准确性方面的影响，其中大部分纳入影响因素的方式被代表性的顺序推荐系统广泛采用。

5.1 实验性设置

5.1.1 数据集。我们使用三个真实世界的数据集。 $RSC15$ 、 $RSC19$ 和 $LastFM$ 。 $RSC15$ 是由RecSys Challenge²⁰¹⁵¹²发布的，它包含了一个在线商店的点击和购买行为。在我们的评估中只使用了点击数据。 $RSC19$ 是由RecSys Challenge²⁰¹⁹¹³发布的，它包含了一个全球酒店平台的酒店搜索会话。 $RSC19$ （用户）是 $RSC19$ 的一个子集。 $LastFM$ 是通过LastFM API收集的，每个样本是一个4元组（用户、艺术家、歌曲、时间戳）。

按照数据预处理的常用方法[34, 78]，对于 $RSC15$ 和 $RSC19$ ，我们首先过滤掉少于2个行为的会话，以及出现少于5次的项目。然后，我们将在最后一天结束的会话作为测试集，而其他会话则用于模型训练/验证。对于 $RSC19$ （用户），我们进一步选择有10个以上会话的用户，并将每个用户的最后一个会话作为测试集。对于 $LastFM$ ，由于LastFM缺乏会话身份，我们手动将每个用户的行为序列划分为每30分钟一个会话。然后，我们过滤掉少于3个行为的会话，出现少于5次的项目，以及出现少于3次的用户。我们还考虑将每个用户的最后一个会话作为测试集。在这里，我们想强调的是，不同的数据过滤方式，会导致不同的数据场景。

¹¹ 实验的源代码和数据集在Github上共享：<https://github.com/sttich/dl-recommendation>。

¹² www.kaggle.com/chadgostopp/recsys-challenge-2015。

¹³ www.recsyschallenge.com/2019/。

将导致不同的性能。例如, 我们通过过滤掉RSC15上小于{2、3、4、5、10、15、20}的会话, 来检查GRU4Rec在不同数据场景下的表现。为了进行公平的比较, 在所有的数据场景下, 我们使用了与上述数据预处理程序后的20个数据场景相同的测试集。我们调整了每个场景下的超参数, 结果如图12所示。如图12所示, GRU4Rec的性能随着序列长度的增加而下降。这可能是由于训练的次数减少造成的, 即在七个数据场景下, RSC数据集的可用训练次数分别为7966888、4419603、2810308、1876772、448561、167318和78486。




图12.会话长度对RSC15的影响。

此外, 需要注意的是, 很少有研究明确讨论他们用于模型训练/验证/测试的数据分割方法。通过阅读相应作者公布的源代码, 我们总结出以下两种主要形式(主要是由于在模型设计中是否考虑了用户信息而有所不同)。(1)将最近 n 天内发生的会话划分为测试集;(2)将每个用户最近的会话作为测试集。在顺序推荐中, 前者被更多地采用。

这些数据集的统计信息汇总于表3。

表3.四个数据集的统计信息。

特点	RSC15	RSC19	RSC19 (用户)	LastFM
会议	7,981,581	356,318	1,885	23,230
项目	37,483	151,039	3,992	122,816
行为	31,708,461	3,452,695	49,747	683,907
用户	-	279,915	144	277
ABS	3.97	9.69	26.39	29.44
美国大学	-	1.27	13.09	83.86

ABS:每个会话的平均行为 ASU:每个用户的平均会话数

t.1.2 模式的选择。我们选择GRU4Rec[34](图9)作为我们的基本模型, 然后考虑图10中的影响因素, 检查它们对基本模型的影响。使用GRU4Rec的主要原因是很多文献中的算法都对它进行了改进, 或者认为它是顺序推荐任务的一个具有代表性和竞争力的基线。这使得GRU4Rec成为展示影响因素对于DL模型的影响的完美选择。具体而言。

表4.不同情况下的其他参数排名。

模型	RSC15			
	批量大小	Lr	RNN大小	辍学率
默认情况下	32	0.2	100	0
GRU4Rec (类别)	50	0.001	100	0.5
C-GRU	50	0.001	120	0.5
P-GRU	50	0.001	100 (项目) , 20 (类别)	0.5
			。	
NARM	512	0.001	100	0.25

模型	RSC19			
	批量大小	Lr	RNN大小	辍学率
默认情况下	32	0.2	100	0
GRU4Rec (行为)	50	0.001	100	0.5
B-GRU	50	0.001	100	0.5
NARM	512	0.001	100	0.25
用户隐式	50	0.001	50	0.5
用户嵌入	50	0.001	50	0.5
用户的重复性	50	0.01	100 (项目) , 100 (用户)	0
) 。	

模型	LastFM			
	批量大小	Lr	RNN大小	辍学率
用户隐式	50	0.001	50	0.5
用户嵌入	50	0.001	50	0.5
用户的重复性	200	0.02	50 (项目) , 50 (用户)	0
) 。	

在我们的实验中，我们专注于广泛探索的基于交易的顺序推荐任务，其目的是在基于交易的顺序基础上预测用户将喜欢/购买的下一个项目。在未来，我们可以考虑使用不同的DL结构的其他代表性模型。

例如，NextItNet[142]（基于CNN的模型）和NARM[53]（基于注意力的模型）。

基本模型的默认参数是没有数据增强，没有用户表示（即隐式用户表示），BPR-max损失函数，RSC15和RSC19的样本量为128的均匀负向采样。在接下来的实验中，如果没有被特别弄清楚，其他模型也使用这些默认设置。

对于输入模块，我们选择两种侧面信息：项目类别和停留时间。对于项目类别，根据以前的研究，我们实现了基本模型的两个改进版本。C-GRU（将物品嵌入与类别嵌入相连接[18]）和P-GRU（对物品和类别分别进行arellely训练两个基本模型，然后将两个子网的输出相连接[35]），采用小批量并行负采样（批量大小=50）。相应的控制模型GRU4Rec（类别）是基本的GRU4Rec模型，除了RNN的大小外，其设置与C-GRU和P-GRU相同。对于停留时间，我们实现了[12]中的模型，根据停留时间的分布，我们选择75秒和100秒作为RSC15的阈值，45秒和60秒作为RSC19的阈值。

为了验证行为类型的影响，我们设计了一个新的网络（B-GRU），在基本模型中增加了一个行为类型嵌入模块。具体来说，B-GRU将项目一热向量和行为类型一热向量作为输入，并将其转换为嵌入向量，其中项目嵌入向量被送入一个GRU模型，其输出与行为类型连接。

为MLP层嵌入向量。目前的设计旨在捕捉这样的直觉：用户在序列中的下一个行为不仅与用户以前互动过的项目序列有关，而且还可能受到用户以前行为类型的影响。此外，B-GRU采用小批量平行负向采样法，样本量为50。相关的控制模型GRU4Rec (Behavior) 是基本的GRU4Rec模型，其设置与B-GRU相同。C-GRU、P-GRU和B-GRU的结构如图13所示。

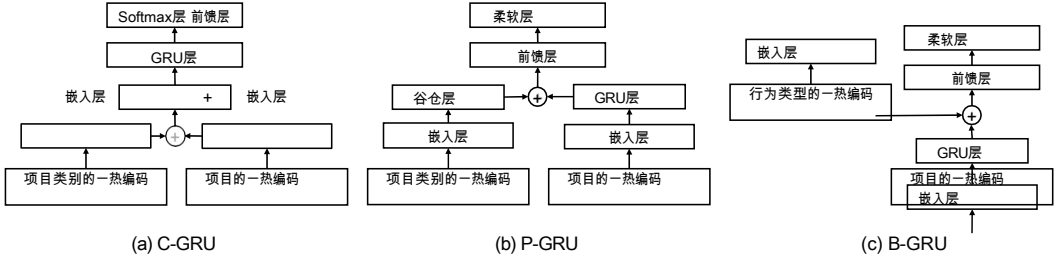


图13.C-GRU、P-GRU和B-GRU的网络结构。

对于数据处理模块，我们在基本模型上实现了[103]中的**数据增强**方法（见图11）。具体来说，我们在训练集中随机选择50%的会话来进行数据扩充，并随机将每个会话的一部分作为新会话。

对于模型结构模块，我们考虑三种结构。**NARM**[53]（**将基本模型与注意力机制结合起来**），[42]中的**加权模型**（**将DL模型与KNN结合起来**），并通过两种方式**增加明确的用户表示**，即[78]中的递归方式（简称**用户递归**），以及通过增加基于用户ID的用户嵌入层的嵌入方式（简称**用户嵌入**），与GRU4Rec基本模型中GRU的输出相连接，并使用与[78]中相同的训练方法）。注意到我们在训练用户递归和嵌入模型时都使用了用户并行小批[78]。

对于模型训练模块，我们考虑三个因素：**损失函数**（即交叉熵、BPR-max、BPR、TOP1-max和TOP1）、**采样方法**（即[33]中的额外采样）和

$\epsilon \in \{0, 0.25, 0.5, 0.75, 1\}$ ，以及负样本的大小 $\{0, 1, 32, 128, 512, 2, 048\}$ 。表4总结了不同数据集方面的其他参数，其中 L_r 指的是这些基于DL的模型的学习率。应该指出的是，我们使用了基本模型（控制模型）的源代码中推荐的默认超参数（例如，批处理量、学习率和RNN大小）。此外，为了证明相应因子的有效性，在实验模型（有因子效应）中，我们将主要的默认超参数固定为与相应的控制模型相同。通过这样的设置，我们的目的是在顺序推荐中有效地展示影响因素（以及设计的成分）的影响，同时最大限度地消除其他因素的影响。

t.1.3 评价湿指标。为了比较不同模型的性能，我们使用三种广泛使用的准确性指标。**Recall@k**, **MRR@k** (Mean Reciprocal Rank) 和 **NDCG@k** (Normalized Discounted Cumulative Gain) 作为以前的顺序推荐模型，其中 k 分别被设置为5、10和20。对于这三个指标，较大的数值意味着更好的性能。我们感兴趣的读者参考[146]，了解召回率和MRR评价指标的详细定义。注意到GRU4Rec是预测用户的下一个行为（**下一个项目预测**），也就是说，推荐列表中只有一个项目会被用户实际选择。在这种情况下，MRR相当于平均精度（MAP），而Recall则与命中率（HR）相同[99]。

- **召回率@k**：它衡量的是校正后的推荐项目在基础真实项目方面的覆盖率。
- **MRR@k**：它指的是一个模型对地面真实项目的排名情况。
- **NDCG@k**：它根据每个地面真实项目在推荐列表中的位置进行奖励，表明一个项目被推荐的强烈程度。

$$\text{NDCG}@k = \frac{1}{\log_2(\square\square\square\square + 1)}$$

其中， $\square\square\square\square$ 表示基础真相项目的排名位置。

需要注意的是，对于每种方法，我们在每个实验中运行5次，并在表5和表6中以 "平均值±标准差" 的形式报告三个指标的性能，并在其他图中显示平均值。

5.2 实验结果

表5. 纳入项目类别或行为类型的结果。各改进模型与基本模型(GRU4Rec)成对差异的统计学意义由成对的□检验确定(*代表p值≤0.1，○代表p值≤0.05，Δ代表p值≤0.01)。

型号	RSC15					
	召回@5	MRR@5	NDCG@5	召回@20	MRR@20	NDCG@20
GRU4Rec	0.313±0.0047	0.168±0.0036	0.203±0.0039	0.554±0.0043	0.192±0.0034	0.273±0.0035
C-GRU	0.328Δ± 0.0023	0.178Δ± 0.0016	0.215Δ± 0.0015	0.564Δ± 0.0032	0.202Δ± 0.0015	0.283Δ± 0.0012
P-GRU	0.335^Δ±0.0014	0.180Δ± 0.0017	0.218^Δ±0.0014	0.570^Δ±0.0018	0.204Δ± 0.0017	0.286^Δ±0.0015

型号	RSC19					
	召回@5	MRR@5	NDCG@5	召回@20	MRR@20	NDCG@20
GRU4Rec	0.568± 0.0065	0.489±0.001	0.509± 0.0017	0.696± 0.0023	0.502±0.0019	0.546± 0.0015
B-GRU	0.586Δ± 0.0025	0.494Δ± 0.0032	0.517^Δ±0.0030	0.708Δ± 0.0008	0.507Δ± 0.0029	0.552^Δ±0.0023

这里，我们系统地介绍了不同影响因素在四个模块方面的实验结果。

t.2.1 输入模块 (Input Wodule)。首先，我们介绍与输入模块有关的因素的实验结果：侧面信息和行为类型。

侧面信息的影响。表5和表6^{分别}显示了两种类型的侧面信息对基于DL模型的影响结果¹⁴。如表5所示，将**项目类别**信息纳入GRU4Rec可以提高模型在所有三个指标方面的性能。具体来说，C-GRU和P-GRU比基本模型表现更好。从表6中我们可以看到，**停留时间**可以大大改善性能，例如，在RSC15和RSC19数据集上，Recall@20分别增加了约28%和19%。总而言之，利用侧面信息可以大大改善模型的性能，而纳入侧面信息的方式也很重要。因此，有必要通过考虑侧面信息对最终预测的影响来进行校准设计。

行为类型的影响。关于行为类型 (B-GRU) 的影响，结果见表5。我们可以看到，B-GRU在所有指标方面都优于基本模型。如果一个数据集提供

¹⁴ 当□=10时，我们有一致的结果。由于篇幅有限，我们不在此报告，而是在Github上报告：https://github.com/sttich/dl-recommendation。

表6. 考虑不同因素的结果。每个改进的模型与基本的GRU4Rec的成对差异的统计学意义由成对的 χ^2 检验来确定 (*代表 p 值 ≤ 0.1 , \circ 代表 p 值 ≤ 0.05 , Δ 代表 p 值 ≤ 0.01)。

因素	变量	农村人口15					
		召回@5	MRR@5	NDCG@5	召回@20	MRR@20	NDCG@20
居住时间	0	0.446 \pm 0.0011	0.268 \pm 0.0007	0.312 \pm 0.0008	0.676 \pm 0.0009	0.293 \pm 0.0006	0.380 \pm 0.0006
	100	0.772$\Delta$$\pm$0.0004	0.692$\Delta$$\pm$0.0005	0.712$\Delta$$\pm$0.0005	0.865$\Delta$$\pm$0.0005	0.702$\Delta$$\pm$0.0005	0.739$\Delta$$\pm$0.0004
	100	0.730 Δ \pm 0.0010	0.635 Δ \pm 0.0007	0.659 Δ \pm 0.0007	0.841 Δ \pm 0.0004	0.647 Δ \pm 0.0006	0.691 Δ \pm 0.0005
数据偏差 ⁴	关于	0.446 \pm 0.0011	0.268\pm0.0007	0.312\pm0.0008	0.676 \pm 0.0009	0.293\pm0.0006	0.380\pm0.0006
	8月1日	0.446\pm0.0018	0.267 \pm 0.0005	0.312 \pm 0.0007	0.678\pm0.0011	0.292 \pm 0.0005	0.379 \pm 0.0005
攻击 ²	在	0.480 \pm 0.0005	0.285 \pm 0.0005	0.334 \pm 0.0005	0.703 \pm 0.0001	0.309 \pm 0.0005	0.400 \pm 0.0004
	在	0.486\pm0.0003	0.290$\Delta$$\pm$0.0002	0.339$\Delta$$\pm$0.0002	0.708$\Delta$$\pm$0.0002	0.314$\Delta$$\pm$0.0003	0.404$\Delta$$\pm$0.0002
KNN重量	0.04	0.446 \pm 0.0011	0.268 \pm 0.0007	0.312 \pm 0.0008	0.676 \pm 0.0009	0.293 \pm 0.0006	0.380 \pm 0.0006
	0.1	0.452 Δ \pm 0.0008	0.270 Δ \pm 0.0003	0.315 Δ \pm 0.0002	0.693 Δ \pm 0.0006	0.296 Δ \pm 0.0005	0.386 Δ \pm 0.0004
	0.3	0.460$\Delta$$\pm$0.0007	0.278$\Delta$$\pm$0.0004	0.323$\Delta$$\pm$0.0004	0.698$\Delta$$\pm$0.0009	0.303$\Delta$$\pm$0.0005	0.393$\Delta$$\pm$0.0003
因素	变量	农村妇女委员会19					
		召回@5	MRR@5	NDCG@5	召回@20	MRR@20	NDCG@20
停留时间	0.04	0.640 \pm 0.0018	0.547 \pm 0.0028	0.571 \pm 0.0025	0.751 \pm 0.0017	0.559 \pm 0.0028	0.602 \pm 0.0025
	45	0.845$\Delta$$\pm$0.0074	0.783$\Delta$$\pm$0.0063	0.799$\Delta$$\pm$0.0065	0.893$\Delta$$\pm$0.0071	0.788$\Delta$$\pm$0.0062	0.813$\Delta$$\pm$0.0063
	60	0.830 \pm 0.0007	0.763 Δ \pm 0.0013	0.780 Δ \pm 0.0011	0.885 \pm 0.0010	0.768 Δ \pm 0.0015	0.795 Δ \pm 0.0013
8月1日数据	关 ⁴	0.640 \pm 0.0018	0.547 \pm 0.0028	0.571 \pm 0.0025	0.751 \pm 0.0017	0.559 \pm 0.0028	0.602 \pm 0.0025
	开启	0.641\pm0.0015	0.551$\circ$$\pm$0.0019	0.574$\circ$$\pm$0.0013	0.754$\circ$$\pm$0.0004	0.562$\circ$$\pm$0.0020	0.606$\circ$$\pm$0.0014
归 ²	关 ⁵	0.736 \pm 0.0015	0.569 \pm 0.0010	0.611 \pm 0.0011	0.905 \pm 0.0009	0.587 \pm 0.0001	0.661 \pm 0.0001
	开启	0.742$\Delta$$\pm$0.0023	0.5726\pm0.0024	0.615$\Delta$$\pm$0.0023	0.912$\Delta$$\pm$0.0012	0.591$\Delta$$\pm$0.0022	0.665$\Delta$$\pm$0.0020
KNN重量	0.04	0.640 \pm 0.0018	0.547 \pm 0.0028	0.571 \pm 0.0025	0.751 \pm 0.0017	0.559 \pm 0.0028	0.602 \pm 0.0025
	0.1	0.643 \pm 0.0039	0.549 \pm 0.0064	0.572 \pm 0.0057	0.753 \pm 0.0034	0.560 \pm 0.0063	0.604 \pm 0.0055
	0.3	0.657$\Delta$$\pm$0.0023	0.562$\Delta$$\pm$0.0067	0.586$\Delta$$\pm$0.0057	0.765$\Delta$$\pm$0.0033	0.573\pm0.0067	0.617\pm0.0057
因素	变量	最后的FM					
		召回@5	MRR@5	NDCG@5	召回@20	MRR@20	NDCG@20
用户代表 ³	隐式 ⁶	0.173$\Delta$$\pm$0.0021	0.147$\Delta$$\pm$0.0018	0.154$\Delta$$\pm$0.0018	0.193$\Delta$$\pm$0.0024	0.149$\Delta$$\pm$0.0018	0.160$\Delta$$\pm$0.0018
	嵌入式	0.006 \pm 0.0011	0.004 \pm 0.0016	0.004 \pm 0.0014	0.016 \pm 0.0026	0.005 \pm 0.0015	0.007 \pm 0.0012
	复发性	0.002 \pm 0.0002	0.001 \pm 0.0002	0.002 \pm 0.0007	0.003 \pm 0.0009	0.002 \pm 0.0005	0.002 \pm 0.0002
因素	变量	RSC19 (用户)					
		召回@5	MRR@5	NDCG@5	召回@20	MRR@20	NDCG@20
用户代表 ³	隐式 ⁶	0.713$\Delta$$\pm$0.0165	0.654$\Delta$$\pm$0.0128	0.668$\Delta$$\pm$0.0130	0.781$\Delta$$\pm$0.0134	0.661$\Delta$$\pm$0.0128	0.688$\Delta$$\pm$0.0125
	嵌入式	0.032 \pm 0.0098	0.023 \pm 0.0092	0.025 \pm 0.0093	0.060 \pm 0.0113	0.025 \pm 0.0090	0.032 \pm 0.0094
	复发性	0.030 \pm 0.0199	0.016 \pm 0.0113	0.019 \pm 0.0131	0.079 \pm 0.0198	0.020 \pm 0.0111	0.033 \pm 0.0126

¹ "Data Aug"指的是数据增殖。

² "Att"指的是注意机制。

³ "用户代表"是指用户代表。

⁴ "0"和"关闭"情况是指不考虑相应的影响因素,即相当于基本的GRU4Rec。

⁵ 这里的"关闭"表示没有注意机制的NARM[53]。

⁶ "隐式"表示没有用户代表。

的行为类型信息,最好用适当设计的模块将其整合到最终模型中,例如,像我们这样的简单模块。

t.2.2 数据处理。在这里,我们检查了有关数据增强的影响。

数据增强的效果。如表6所示,在RSC15中,有数据增强的模型在召回率@20方面比基本模型的表现略好(0.2%),但在MRR@20方面则较差。

和NDCG@20。在RSC19上,数据的增加提高了模型在所有指标方面的性能,但显著性水平较低(即5%)。类似的混合结果可以观察到,当 $\alpha=5$ (见表6)。总之,对于GRU4Rec模型来说,简单的数据扩充并不能显著提高模型的性能。我们可以考虑根据GRU4Rec模型的特点,设计更复杂的方法。

t.2.3 **模型结构**。在本小节中,我们介绍了关于改变DL结构的实验结果。

纳入注意力机制的效果。如表6所示,纳入**注意力机制**后,几乎在所有情况下都增强了模型的性能。

与传统方法结合的效果。将基本模型与KNN相结合,在RSC15和RSC19上都提高了模型的性能,KNN权重为0.3,比0.1的性能更好,体现了传统模型与DL模型相结合的方式对顺序推荐有很大的影响。

用户表示效果。Implicit代表基本的GRU4Rec模型,采用会话并行的小批量方法。递归和嵌入指的是以两种不同的方式添加明确的用户表示,这在第5.1.2节中讨论过。对于用户表示,我们发现增加一个明确的用户表示模块,无论是嵌入的还是递归的,都会导致所有指标的急剧下降。为了补充调查,我们调整了用户递归和用户嵌入模型的主要超参数(如批处理大小、学习率和RNN大小等),发现这两个模型与基本模型之间的巨大差距不能被明显减少。主要原因可能有三方面。1)隐式模型采用会话并行小批(一个会话作为样本),而用户嵌入式和递归模型采用用户并行小批(一个用户的所有历史会话作为样本)。在这种情况下,用户嵌入模型和递归模型的训练样本要比隐式模型少得多(由于我们没有找到在GRU4Rec中直接加入用户嵌入的具体模型,所以我们也参考了文献[78]中的训练方法来训练用户嵌入模型);2)如表3所示,在这两个数据集上,会话的数量远远大于用户的数量;3)根据表3所示的项目和行为的数据,这两个数据集上项目的平均支持要小得多。值得一提的是,正如文献[78]所报道的,在他们的两个数据集上,具有递归用户表示的GRU4REC比原始模型表现得更好。此外,我们可以看到,在大多数情况下,用户嵌入模型的表现优于用户递归模型,但在RSC19(用户)上,在召回率@20和NDCG@20方面的表现不如递归模型。在这种情况下,在个性化顺序推荐中,我们可以推断出是选择用户嵌入模型还是递归模型很大程度上取决于数据集的特点和应用场景。然而,是否考虑显式用户表示模型,不仅取决于应用场景,还取决于精心设计的用户表示组件。

t.2.4 **训练模型**。这里,我们从抽样方法、样本大小和损失函数三个因素的角度来介绍实验结果。

采样方法的影响。图14和15分别描述了在RSC15和RSC19上不同 α 的模型性能,其中不同数据集上的结果是不同的。对于RSC15,交叉熵、BPR-max和TOP1-max(在所有指标上)的表现是一致的。它们首先随着 α 从0增加到0.25而慢慢增加,然后随着 α 大于0.25而减少。此外,在RSC15上,不同损失函数和指标所对应的最佳 α 都是一样的。相反,在RSC19上,对于不同的损失函数和不同的评价指标,最佳 α 是不同的。例如,就Recall@20而言,BPR-max损失函数的最佳 α 为0.5,但就交叉熵而言,则为0。因此,有必要进行




图14. \square 对RSC15额外采样策略的影响 (XE: 交叉熵; B-m: BPR-max; T-m: TOP1-max)。




图15. \square 对附加采样策略对RSC19的影响 (XE: 交叉熵; B-m: BPR-max; T-m: TOP1-max)。




图16. 样本量对RSC15的影响。

在验证集中进行充分的搜索, 以找出关于现实世界应用中最有价值的评价测量的采样策略和损失函数的最佳组合。负样本的大小影响。如图16所述, 负样本的大小越大, 基本模型在所有评价测量方面的性能越好。特别是, 当大小从0增加到32时, 模型的性能得到了极大的改善, 而随着大小的进一步增加, 增加的速度下降。对RSC19的实证结果




图17.样本量对RSC19的影响。




图18.不同损失函数在RSC15上的模型表现 (B-m: BPR-max; T-m: Top1-max; XE: cross-entropy)。




图19.不同损失函数在RSC19上的模型表现 (B-m: BPR-max; T-m: Top1-max; XE: cross-entropy)。

(图17) 几乎相似, 但当样本量从32到128时, 在MRR和NDCG方面有轻微的下降。应该注意的是, 额外的负采样会导致更高的计算成本。因此, 在实际应用中, 我们需要考虑负样本的大小, 在模型性能和训练时间之间保持一个平衡。

损失函数的影响。如图18和19所示, 使用**损失函数**BPR-max、TOP1-max和交叉熵的模型在所有指标上都比使用BPR和TOP1的模型表现更好, 但这三种损失函数中的最佳损失函数也取决于数据集。总的来说, 建议在现实世界的应用中部署这三个损失函数。

t.2.t 结论性意见。实验结果验证了第4节中总结的影响因素在基于DL的顺序推荐中都发挥了重要作用。我们对实践中的最佳建议总结如下。1) 在允许的情况下, 尝试所有可能的侧面信息(如文本和图片), 并仔细设计相应的模块; 2) 充分考虑其他行为类型与目标行为之间的联系, 在对这些联系进行建模时, 要注意最终推荐中可能涉及的噪声信息。3) 始终结合TOP1-max、BPR-max和交叉熵损失函数进行训练, 在模型性能和计算成本之间保持平衡, 并谨慎选择/设计数据增强策略以进一步提高相应的推荐性能, 特别是当可用的训练集相对较小时; 4) 对于任何基于DL的模型, 考虑用注意力机制进一步提高其性能, 可以与传统的顺序学习模型相结合, 并精心设计一个适应相应数据场景的显式用户表示模块。

6 未来的方向和结论

6.1 未来的方向

正如我们所讨论的, DL技术极大地促进了顺序推荐的研究, 但也伴随着一些挑战性的问题。因此, 我们总结了以下开放性问题, 这些问题可以被认为是基于DL的顺序推荐系统的未来方向。

6.1.1 对不同的模型进行严格和全面的评估。我们的实证研究可以被看作是对GRU4Rec及其变体的横向调查。在文献中, 很多GRU4Rec的变体都将GRU4Rec[34]作为基线, 但这些变体之间的比较却很少。在这种情况下, 很难判断在特定的应用场景下哪一个更好。此外, 也可以考虑其他有竞争力的基线, 例如NextItNet[142](基于CNN的模型), NARM[53](基于注意力的模型), 或者进一步参考[64]中提出的比较框架。越来越多的人认为, 只有复杂的深度学习结构并不能总是保证更好和更稳健的推荐系统[19, 102]。此外, 有一个关键问题在推荐系统领域引起了越来越多的关注: 很少有有效的评估基准, 特别是在顺序推荐方面。因此, 严格和全面评价的基准研究应该被紧急提上研究议程。

6.1.2 可解释的顺序推荐系统。正如已经指出的, 大多数基于DL的模型缺乏可解释性, 被认为是平台从业者和用户的黑箱。因此, 设计可解释的顺序推荐系统是非常重要的。一方面, 如果了解预测背后的原因, 用户将不愿意充分信任单个预测, 从而根据它采取行动。另一方面, 模型从业者努力充分理解模型(即不同的因素, 如数据、特征和模型的超参数如何影响模型的输出? 注意到我们的调查揭示了第二个问题, 更多的想法可以从那些对深度学习网络的可解释性研究中借鉴[3, 46, 72, 88]

对于第一个问题, 主要有两类可解释的推荐方法, 试图让用户理解为什么推荐这样的项目或列表: 基于模型和事后的方法[148]。基于模型的方法旨在设计可解释的算法来同时

为用户提供准确和可解释的推荐项目（大多使用多任务学习框架）。除了用户与项目之间的互动，他们通常会结合侧面信息（如文本和视觉项目描述、文本评论、社会信息）来促进可解释的任务。例如，Huang等人[40]在顺序推荐中利用知识图谱来实现更好的可解释性。相比之下，由于没有直接将解释与推荐的侧面信息联系起来，事后方法[74]试图设计单独的方法来解释那些基于黑箱的推荐算法产生的推荐结果。

6.1.3 对不同的组件进行更多的设计，以促进推荐的进行。在实证结果的基础上，我们认为可以在以下组件上投入更多的精力，这些组件可以被纳入每个顺序推荐模型，以相应地提高推荐性能。

更多关于嵌入方法的设计。以前的研究大多采用NLP中的嵌入方法。然而，在顺序推荐中，预先训练一个嵌入模型（例如word2vec）是相当有挑战性的，因为项目信息和项目之间的依赖关系是不断变化的，而NLP中的词和它们的连接是相对固定和静态的。另一方面，顺序推荐中的行为也比词非常复杂，因为它们同时涉及行为对象和类型。此外，在现有的顺序推荐模型中，嵌入向量的整合也是以一种相对简单的方式进行的。在这种情况下，需要为顺序推荐设计更先进和特殊的嵌入方法[111]。例如，[58]设计了一种顺序嵌入方法，该方法在顺序推荐中也考虑到了项目及其属性之间的依赖关系。一个可能的解决方案是利用度量学习的优势[106]，通过理解序列数据获得更好的项目、用户或序列表示。度量学习侧重于捕捉数据之间的重要关系的距离度量[50]，并且已经被验证在传统的静态推荐任务中是有效的[37, 134]。

更好地对用户的长期偏好进行建模。在我们的研究和经验调查的基础上，基于DL的模型中的用户表示模块（尤其是长期偏好）与所设计的项目表示模块相比，还远远不够理想。在这种情况下，进一步的研究可以考虑为用户表示设计更有利的模块，以及思考如何更好地将用户的长期偏好和短期偏好结合起来。

先进的抽样策略。在顺序推荐中，大多数现有的研究使用了统一的、基于流行度的或者它们的直接组合（即附加抽样）的抽样策略，与NLP中使用的策略相比，这些策略相对简单。在这种情况下，未来的研究可以考虑从其他领域（例如NLP或图表示[124, 136]）借用或扩展更先进的抽样策略。

6.1.4 基于多态行为轨迹的个性化推荐。我们将行为序列总结为三种类型，据我们所知，在基于交互的序列推荐任务中，很少有研究能很好地区分行为类型并对它们的联系进行建模。我们的实证评估也表明，很好地考虑目标类型的另一种行为类型是非常具有挑战性的。在这种情况下，可以通过考虑多态行为类型之间的联系来设计更多的DL模型，从而在顺序推荐中获得更好的推荐性能。例如，Qiu等人[76]提出了一个异质行为类型的贝叶斯个性化排名模型（BPRH），该模型将目标行为、辅助行为和消极行为纳入一个统一的模型，该想法可能也适用于顺序推荐。此外，更高级的深度学习模型，如异质网络的GNN[52]，也可以考虑用来实现这一目标。例如，Song等人[95]提出了一个动态图-注意力

神经网络来捕捉动态的用户偏好序列和社会影响（社会网络），以便更好地推荐。

6.1.t 实时学习行为序列。用户的每一个行为都可能反映出可能的兴趣转移，在这种情况下，推荐系统要理想地捕捉这种信息，并及时证明推荐策略的合理性。强化学习是解决这个问题一个有希望的选择。例如，Zhao等人[151]在电影推荐中结合MF、RNN和GAN来动态地提供电影推荐。Shih等人[90]将音乐播放列表的生成视为一个语言建模问题，并在强化学习中使用基于注意力的语言模型和策略梯度。

此外，基于DL的模型的另一个重要问题是其可扩展性，模型应该能够处理越来越多的数据量。例如，为了加快再训练程序，[150]设计了一种新的训练方法（又称顺序元学习方法），其目的是通过学习转移过去的训练经验来放弃历史数据。此外，由于在图像识别中被验证为有效和高效[36, 135]，知识提炼技术也开始被引入到推荐系统中[114]。例如，Tang和Wang[114]通过将知识蒸馏技术用于学习排名问题，提出了排名蒸馏（RD）方法。实验结果表明，使用不到一半的模型参数的学生模型可以获得与教师模型相似或更好的排名性能。Chen等人[16]将带有外部知识（如在线评论）的推荐问题制定为一个通用的蒸馏框架，该框架同时兼顾了推荐模型的有效性和效率。

6.1.6 特定领域和跨领域的顺序推荐。很少有研究专门为不同的应用领域确定合适的推荐算法，而大多数研究都假设他们的模型适用于所有领域的顺序推荐任务。未来的研究可以通过捕捉这些领域的特征，为特定领域设计特定的模型，这对现实世界的应用更有价值。另一方面，越来越多的大公司倾向于在不同领域提供服务/产品。例如，ByteDance（bytedance.com）同时向用户提供新闻服务和视频服务。与单领域推荐相比，跨领域推荐解决了利用不同领域的数据来产生理想推荐的问题[13]，其中主要的基本思想是将源领域的知识转移到目标领域，从而进一步提升目标领域的推荐性能。沿着这个思路，由于深度学习很适合在不同领域之间转移知识[147]，未来的研究可以考虑很好地研究不同领域的顺序数据的特点，设计更先进的跨领域顺序推荐模型。例如，Zhuang等人[155]利用一个用户在不同领域的序列行为数据，挖掘她/他的求新特质以提高推荐性能。Ma等人[68]进一步将跨域顺序推荐问题表述为一个平行顺序推荐问题。考虑到两个领域的用户行为在每个时间戳都是同步共享的，他们提出了□-Net（即由一个共享账户过滤单元和一个跨域转移单元），以同时产生对两个域的推荐。

6.1./ 迈向稳健的顺序推荐模型。由于数据分布的不同，单一的模型不能保证在不同的应用场景下有一致的表现，这是一个常识。换句话说，一个模型可能相对脆弱，容易受到数据样本的对抗性扰动（例如，噪声数据或有目的的用户资料攻击[71]）。为了应对这一挑战，一些模型引入了去噪技术[1, 123]，例如，基于AE的去噪技术

首先, 通过使用人为的噪音来破坏数据[132]。此外, 对抗性训练[32, 104, 143]也被采用来提高基于DL的推荐算法的鲁棒性。例如, Yuan等人[143]为基于神经网络的推荐模型提出了一个通用的对抗性训练框架, 并进一步设计了一个用于非线性模型优化的minmax游戏。他们在修改后的协作去噪AE (CDAE) 模型上测试了该框架的有效性[132]。此外, 考虑到以前的对抗训练技术可能忽略了考虑序列数据的特点, Jia等人[43]设计了一种新的针对序列数据的对抗训练方法, 具体回答了何时以及如何扰动一个序列。

6.1.8 解决顺序推荐的冷启动和数据稀疏性挑战。冷启动和数据稀少是推荐系统的长期挑战, 包括顺序推荐[25, 101]。我们之前讨论的大多数现有的顺序推荐算法都忽略了解决这两个问题, 因为它们的有效实现依赖于对顺序数据的相对严格的要求 (例如, 丢弃短于最小阈值的顺序)。因此, 未来的研究在为现实世界的应用建立实用的顺序推荐系统时可以考虑这两个问题。

为了解决这两个问题, 首先, 可以采用能够从有限的样本中学习的机器学习技术 (例如, 少数次学习[125]), 用于顺序推荐。少数次学习致力于弥合人工智能和类人学习之间的差距, 并能通过纳入先验知识和部署不同的ML技术 (例如, 元学习、嵌入学习和生成式建模方法), 在有限的信息中学习一项任务[125]。例如, Du等人[25]提出了 s^2 Meta (Scenario-specific Sequential Meta learner), 它将特定场景的学习与模型无关的顺序元学习相结合, 以实现更有效的推荐。其次, 顺序推荐算法可以建立在不同类型的侧面信息 (如社交网络、用户资料、物品描述和知识图谱) 上, 以部分缓解这两个问题[69, 101], 而深度神经网络相当适合处理多模式信息。例如, *SDM*考虑了多种类型的侧面信息, 如物品ID、第一层类别、叶子类别、品牌和商店, 以更好地模拟用户的长期偏好。

6.2 结论

该研究系统地研究了基于DL的顺序推荐。具体来说, 我们设计了一个新的分类法, 用于研究三类行为序列的顺序推荐任务: 基于经验、基于交易和基于交互。在此基础上, 我们调查并探索了大量基于DL的顺序推荐算法, 目的是为了更好地了解对顺序推荐任务的研究是充分的还是不足的。第三, 为了更好地指导基于DL的顺序推荐系统的发展, 我们从模型输入、数据处理、模型结构和模型训练这四个方​​面彻底确定了影响基于DL的模型在推荐准确性方面表现的可能影响因素。我们进一步通过精心设计的评估全面展示了它们的影响, 这可以看作是一个测试平台。最后, 我们讨论了所面临的挑战, 并为基于DL的顺序推荐的研究提供了新的潜在方向。

参考文献

- [1] Xavier Amatriain, Josep M Pujol, Nava Tintarev, and Nuria Oliver. 2009. 再次评价：通过用户重新评价提高推荐的准确性。In *RecSys*. 173-180.
- [2] Ashton Anderson, Ravi Kumar, Andrew Tomkins, and Sergei Vassilvitskii. 2014. 重复消费的动态变化。在 *WWW*. 419-430.
- [3] Sebastian Bach, Alexander Binder, Grégoire Montavon, Frederick Klauschen, Klaus-Robert Müller, and Wojciech Samek. 2015. 关于通过层级相关性传播对非线性分类器决策的像素级解释。 *PloS One* 10, 7 (2015).
- [4] Dzmitry Bahdanau, Kyunghyun Cho, and Yoshua Bengio. 2015. 通过联合学习 Align 和 翻译的神经机器翻译。在 *ICLR*.
- [5] 白婷, 聂建云, 赵维新, 朱玉涛, 杜攀, 文继荣. 2018. 用于下一个购物篮推荐的属性感知神经 殷勤模型。In *SIGIR*. 1201-1204.
- [6] Trapit Bansal, David Belanger, and Andrew McCallum. 2016. Ask the GRU: Multi-task learning for deep text recommendations. 在 *RecSys*. 107-114.
- [7] Oren Barkan 和 Noam Koenigstein. 2016. Item2vec：协同过滤的神经项目嵌入。在 *第26届 信号处理的机器学习国际研讨会 (MLSP)*。1-6.
- [8] Zeynep Batmaz, Ali Ihsan Yurekli, Alper Bilge, and Cihan Kaleli. 2018. 关于推荐人的深度学习的评论 系统：挑战和补救措施。 *Artificial Intelligence Review* (2018), 1-37.
- [9] Yoshua Bengio, Rejean Ducharme, Pascal Vincent, and Christian Janvin. 2003. 一个神经概率语言模型。 *机器学习研究杂志* 3, 6 (2003), 1137-1155.
- [10] Rahul Bhagat, Srevatsan Muralidharan, Alex Lobzhanidze, and Shankar Vishwanath. 2018. Buy It Again: 重复购买建议的建模。In *KDD*. 62-70.
- [11] Homanga Bharadhwaj 和 Shruti Joshi. 2018. 时间性建议的解释。 *Künstliche Intelligenz* 32, 4 (2018), 267-272.
- [12] Veronika Bogina 和 Tsvi Kuflik. 2017. 在基于会话的推荐中纳入停留时间的循环 神经网络。In *RecTemp@ RecSys*. 57-59.
- [13] Iván Cantador, Ignacio Fernández-Tobías, Shlomo Berkovsky, and Paolo Cremonesi. 2015. 跨领域推荐人 系统。In *Recommender systems handbook*. Springer, 919-959.
- [14] Wanyu Chen, Pengjie Ren, Fei Cai, and Maarten de Rijke. 2019. 用意图感知的多样化改进端到端顺序推荐。 *arXiv 预印本 arXiv:1908.10171* (2019)。
- [15] 陈旭, 徐宏腾, 张永峰, 唐家喜, 曹一心, 秦正, 和 查宏远. 2018. 带有用户记忆网络的序列 推荐。在 *WSDM* 中。 108-116.
- [16] Xu Chen, Yongfeng Zhang, Hongteng Xu, Zheng Qin, and Hongyuan Zha. 2018. Adversarial distillation for efficient recommendation with external knowledge. *tois* 37, 1 (2018), 1-28.
- [17] Kyunghyun Cho, Bart Van Merriënboer, Dzmitry Bahdanau, and Yoshua Bengio. 2014. 论神经 机器翻译的特性。编码器-解码器方法。 *arXiv 预印本 arXiv:1409.1259* (2014)。
- [18] Paul Covington, Jay Adams, and Emre Sargin. 2016. 用于 YouTube 推荐的深度神经网络。In *RecSys*. 191-198.
- [19] Maurizio Ferrari Dacrema, Paolo Cremonesi, and Dietmar Jannach. 2019. 我们真的取得了许多进展吗？近期神经推荐方法的令人担忧的分析。在 *RecSys (RecSys '19)*。ACM, New York, NY, USA, 101-109. <https://doi.org/10.1145/3298689.3347058>
- [20] Alexander Dallmann, Alexander Grimm, Christian Pölitz, Daniel Zoller, and Andreas Hotho. 2017. 通过利用停留时间，用递归神经网络改进会话 推荐。 *arXiv 预印本 arXiv:1706.10231* (2017)。
- [21] James Davidson, Benjamin Liebald, Junning Liu, Palash Nandy, Taylor Van Vleet, Ullas Gargi, Sujoy Gupta, Yu He, Mike Lambert, and Blake Livingston. 2010. YouTube 视频推荐系统。In *RecSys*. 293-296.
- [22] Robin Devooght 和 Hugues Bersini. 2017. 使用递归神经网络的长期和短期建议。在 *UMAP*. 13-21.
- [23] Jingtao Ding, Guanghui Yu, Xiangnan He, Yuhuan Quan, Yong Li, Tat-Seng Chua, Depeng Jin, and Jiajie Yu. 2018. 用视图数据改进隐式推荐系统。In *IJCAI*. 3343-3349.
- [24] Tim Donkers, Benedikt Loepp, and Jürgen Ziegler. 2017. 基于用户的顺序性递归神经网络推荐 dations。In *RecSys*. 152-160.
- [25] 杜正晓, 王晓伟, 杨红霞, 周敬仁, 唐杰. 2019. 用于在线推荐的序列特定场景元 学习者。In *KDD*. 2895-2904.
- [26] 陈高, 何湘南, 甘丹华, 陈湘宁, 冯富礼, 李勇, 蔡达生, 姚丽娜, 宋阳, 金德鹏. 2019. 学会用多种级联行为进行推荐。 *IEEE Transactions on Knowledge and Data Engineering* (2019).

- [27] Asnat Greenstein-Messica, Lior Rokach, and Michael Friedman.2017.使用项目 嵌入的基于会话的推荐。在*IIUI*中。629-633.
- [28] Guibing Guo, Huihui Qiu, Zhenhua Tan, Yuan Liu, Jing Ma, and Xingwei Wang.2017.通过 多类型的辅助隐性反馈来解决推荐系统的数据稀疏性。*Knowledge-Based Systems* 138 (2017), 202-207.
- [29] Ruining He, Chen Fang, Zhaowen Wang, and Julian McAuley.2016.Vista. 一个具有视觉、社交和时间意识的 , 用于艺术推荐的模型。In *RecSys*.309-316.
- [30] Ruining He, Wang-Cheng Kang, and Julian McAuley.2017.基于翻译的推荐。In *RecSys*.161-169.
- [31] 何瑞宁和朱利安-麦考利. 2016.将相似性模型与马尔科夫链融合在一起, 用于稀疏的顺序推荐- dation。In *ICDM*.191-200.
- [32] 何湘南, 何占魁, 杜晓宇, 和蔡达生. 2018.用于推荐的对抗性个性化排名 tion。In *SIGIR*.355-364.
- [33] Balázs Hidasi和Alexandros Karatzoglou. 2018.基于会话的Top-k收益的递归神经网络 推荐。在*CIKM*. 843-852.
- [34] Balázs Hidasi, Alexandros Karatzoglou, Linas Baltrunas, and Domonkos Tikk.2016.基于会话的推荐 与递归神经网络 。在*ICLR*。
- [35] Balázs Hidasi, Massimo Quadrana, Alexandros Karatzoglou, and Domonkos Tikk.2016.并行递归神经 网络架构, 用于基于特征的会议推荐。In *RecSys*.241-248.
- [36] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean.2015.Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531* (2015) .
- [37] 谢承康, 杨龙旗, 崔寅, 林宗义, Serge Belongie, 和Deborah Estrin. 2017.协作式 度量学习。In *WWW*.193-201.
- [38] 徐凯春, 周思宇, 杨毅轩, 和池大石. 2016.基于神经网络的下一首歌曲推荐。*arXiv预印本arXiv:1606.07722* (2016) 。
- [39] 胡浩基, 何向南, 高晋阳, 张志立. 2020.个人化物品频率信息建模 , 用于下一篮子的推荐。In *SIGIR*.
- [40] Jin Huang, Wayne Xin Zhao, Hongjian Dou, Ji-Rong Wen, and Edward Y Chang.2018.用知识增强的记忆网络改进顺序 推荐。In *SIGIR*.505-514.
- [41] 黄小文, 钱胜生, 方泉, 桑继涛, 和徐长生. 2018.CSAN: Contextual self-attention network for user sequential recommendation.In *MM*.447-455.
- [42] Dietmar Jannach和Malte Ludewig. 2017.当递归神经网络满足基于会话的邻域 推荐。In *RecSys*.306-310.
- [43] Xiaowei Jia, Sheng Li, Handong Zhao, Sungchul Kim, and Vipin Kumar.2019.迈向稳健和判别性的 顺序数据学习。何时以及如何进行对抗性训练? In *KDD*.1665-1673.
- [44] Santosh Kabbur, Xia Ning, and George Karypis.2013.Fism : 用于top-n推荐人的因子项目相似性模型 系统。In *KDD*.659-667.
- [45] Wang-Cheng Kang and Julian McAuley.2018.自我关注的顺序推荐。In *ICDM*.IEEE, 197-206.
- [46] 彭玮珂和梁珮琪. 2017.通过影响函数理解黑盒预测。在*ICML*. JMLR. org , 1885-1894.
- [47] Yehuda Koren.2009.具有时间动态的协同过滤。In *KDD*.ACM, 447-456.
- [48] Artus Krohn-Grimberghe, Lucas Drumond, Christoph Freudenthaler, and Lars Schmidt-Thieme.2012.多关系 矩阵分解, 使用贝叶斯的个性化排名来处理社交网络数据。在*WSDM*中。173-182.
- [49] Duc-Trong Le, Hady W Lauw, and Yuan Fang.2018.用孪生网络对同时发生的篮子序列进行建模 , 用于下一个项目的推荐。In *IJCAI*.3414-3420.
- [50] Joonseok Lee, Sami Abu-El-Haija, Balakrishnan Varadarajan, and Apostol Natsev.2018.协作式深度度量 , 用于视频理解的学习。在*KDD*中。481-490.
- [51] Lukas Lerche, Dietmar Jannach, and Malte Ludewig.2016.论电子商务推荐中的提醒的价值-- dations。在*UMAP*中。27-35.
- [52] 李晖, 王彦林, 柳子玉, 和史杰明. 2020.多任务学习在异质性 信息网络上的推荐.*TKDE* (2020).
- [53] Jing Li, Pengjie Ren, Zhumin Chen, Zhaochun Ren, Tao Lian, and Jun Ma.2017.基于神经殷勤的会话 推荐。在*CIKM*. 1419-1428.
- [54] 李嘉诚, 王玉洁, 和朱利安-麦考利. 2020.时间间隔意识到的顺序推荐的自我关注。In *WSDM*.322-330.
- [55] 李胜, Jaya Kawale, 和傅云. 2015.通过边缘化去噪自动编码器进行深度协作过滤。在*CIKM*.811-820.
- [56] Zhi Li, Hongke Zhao, Qi Liu, Zhenya Huang, Tao Mei, and Enhong Chen.2018.从历史和现在学习 : 通过辨别性地利用用户行为进行下一个项目推荐。In *KDD*.1734-1743.

- [57] Greg Linden, Brent Smith, and Jeremy York.2003.亚马逊网站推荐:项目对项目的协同过滤。*IEEE 互联网计算*7, 1 (2003), 76-80.
- [58] Kuan Liu, Xing Shi, and Prem Natarajan.2018. Heterogeneous Attributes的项目推荐的顺序嵌入方法。*arXiv.cs.LR/1805.11008*
- [59] Qiang Liu, Shu Wu, Diyi Wang, Zhaokang Li, and Liang Wang.2016.语境感知的顺序推荐。在 *ICDM*。1053-1058.
- [60] Qiang Liu, Shu Wu, and Liang Wang.2017.递归对数线性模型的多行为顺序预测。*TKDE* 29, 6 (2017), 1254-1267.
- [61] Qiao Liu, Yifu Zeng, Refuoe Mokhosi, and Haibin Zhang.2018.STAMP:短期注意力/内存优先级模型,用于基于会话的推荐。In *KDD*.1831-1839.
- [62] Babak Loni, Roberto Pagano, Martha Larson, and Alan Hanjalic.2016.贝叶斯个性化排名与多道用户反馈。In *RecSys*.361-364.
- [63] Pablo Loyola, Chen Liu, and Yu Hirate.2017.用基于注意力的编码器-解码器对用户会话和意图进行建模。In *RecSys*.147-151.
- [64] Malte Ludewig 和 Dietmar Jannach.2018.基于会话的推荐算法的评估。*用户建模和用户适应性交互*28, 4-5 (2018), 331-390.
- [65] Fuyu Lv, Taiwei Jin, Changlong Yu, Fei Sun, Quan Lin, Keping Yang, and Wilfred Ng.2019.SDM:用于在线大规模推荐系统的序贯深度匹配模型。In *CIKM*.2635-2643.
- [66] Chen Ma, Peng Kang, and Xue Liu.2019.顺序推荐的分层门控网络。In *KDD*.825-833.
- [67] Mingyuan Ma, Sen Na, Cong Xu, and Xin Fan.2018.基于图的广义行为感知推荐系统,用于互动新闻。*arXiv预印本arXiv:1812.00002* (2018)。
- [68] 马慕阳, 任鹏杰, 林玉洁, 陈竹民, 马骏, 和Maarten de Rijke.2019. π -Net:A Parallel Information-sharing Network for Shared-account Cross-domain Sequential Recommendations.In *SIGIR*.685-694.
- [69] 孟文静, 杨德庆, 和肖扬华.2020.将用户的微观行为和物品知识纳入多任务学习,用于基于会话的推荐。在 *SIGIR*.
- [70] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean.2013.矢量空间中单词表征的高效估计。*arXiv预印本arXiv:1301.3781* (2013)。
- [71] Bamshad Mobasher, Robin Burke, Runa Bhaumik, and Chad Williams.2007.迈向值得信赖的推荐人系统。攻击模型和算法稳健性的分析。*TOIT* 7, 4 (2007), 23-es.
- [72] Grégoire Montavon, Wojciech Samek, and Klaus-Robert Müller.2018.解释和理解深度神经网络的方法。*数字信号处理*73 (2018), 1-15.
- [73] Hanh TH Nguyen, Martin Wistuba, Josif Grabocka, Lucas Rego Drumond, and Lars Schmidt-Tieme.2017.用于标签推荐的个性化深度学习。在 *PAKDD*中。186-197.
- [74] 乔治娜·皮克和王俊.2018.解释的挖掘。用于推荐系统的潜在因素模型的事后可解释性。In *KDD*.2060-2069.
- [75] Jeffrey Pennington, Richard Socher, and Christopher Manning.2014.手套。全局向量的单词表示。在 *EMNLP* 中。1532-1543.
- [76] Huihuai Qiu, Yun Liu, Guibing Guo, Zhu Sun, Jie Zhang, and Hai Thanh Nguyen.2018.BPRH:异质性隐性反馈的贝叶斯个性化排名。*Information Sciences* 453 (2018), 80-98.
- [77] Massimo Quadrana, Paolo Cremonesi, and Dietmar Jannach.2018.序列感知的推荐系统。*ACM Computing Surveys (CSUR)* 51, 4 (2018), 1-36.
- [78] Massimo Quadrana, Alexandros Karatzoglou, Balázs Hidasi, and Paolo Cremonesi.2017.用分层递归神经网络实现基于会话的个性化推荐。In *RecSys*.130-137.
- [79] Yogesh Singh Rawat和Mohan S Kankanhalli.2016.ConTagNet:利用用户背景进行图像标签推荐-dation。In *MM*.1102-1106.
- [80] Kan Ren, Jiarui Qin, Yuchen Fang, Weinan Zhang, Lei Zheng, Weijie Bian, Guorui Zhou, Jian Xu, Yong Yu, Xiaoqiang Zhu, et al. 2019.用于用户响应预测的个性化记忆的终身序列模型。在 *SIGIR*.565-574.
- [81] 任鹏杰, 陈竹民, 李静, 任兆春, 马骏, 和Maarten de Rijke.2019.RepeatNet:一个重复感知的神经推荐机,用于基于会话的推荐。In *AAAI*, Vol. 33.4806-4813.
- [82] Steffen Rendle, Christoph Freudenthaler, Zeno Gantner, and Lars Schmidt-Thieme.2009.BPR:来自隐性反馈的贝叶斯个性化排名。在 *UAI* 中。452-461.
- [83] Steffen Rendle, Christoph Freudenthaler, and Lars Schmidt-Thieme.2010.用于下一篮子推荐的因子化个性化马尔科夫链。在 *WWW*。811-820.
- [84] Steffen Rendle, Zeno Gantner, Christoph Freudenthaler, and Lars Schmidt-Thieme.2011.用因子化机器进行快速的下上下文感知建议。In *SIGIR*.635-644.

- [85] Massimiliano Ruocco, Ole Steinar Lillestøl Skrede, and Helge Langseth.2017.基于会话的会话建模 推荐。在 *第二届推荐系统深度学习研讨会* 上。24-31.
- [86] Noveen Sachdeva, Kartik Gupta, and Vikram Pudi.2018.融入歌曲特征的关注性神经架构 , 用于音乐推荐。In *RecSys*.417-421.
- [87] Noveen Sachdeva, Giuseppe Manco, Ettore Ritacco, and Vikram Pudi.2019.用于 协同过滤的序列变异自动编码器。在 *WSDM*。
- [88] Thomas Schnake, Oliver Eberle, Jonas Lederer, Shinichi Nakajima, Kristof T Schütt, Klaus-Robert Mller, and Grégoire Montavon.2020.XAI for Graphs: *arXiv preprint arXiv:2006.03589* (2020). XAI for Graphs: Explaining Graph Neural Network Predictions by Identifying Relevant Walks.
- [89] Tian Shi, Yaser Keneshloo, Naren Ramakrishnan, and Chandan K Reddy.2018.用序列到序列模型进行神经抽象化文本总结 。 *arXiv 预印本 arXiv:1812.02303* (2018)。
- [90] 石顺尧和池恒宇。2018.使用强化 学习的自动、个性化和灵活的播放列表生成。 *arXiv 预印本 arXiv:1809.04214* (2018)。
- [91] Ajit P Singh and Geoffrey J Gordon。2008.通过集体矩阵分解进行关系学习。In *KDD*.650-658.
- [92] Ayush Singhal, Pradeep Sinha, and Rakesh Pant.2017.在现代推荐系统中使用深度学习。A 最近的工作总结。 *IJCA* (2017)。
- [93] Elena Smirnova and Flavian Vasile。2017.用递归神经 网络进行推荐的语境序列建模。In *the 2nd Workshop on Deep Learning for Recommender Systems*.2-9.
- [94] Harold Soh, Scott Sanner, Madeleine White, and Greg Jamieson.2017.用于个人、 自适应用户界面的深度顺序推荐。在 *IUI* 中。589-593.
- [95] 宋卫平, 肖志平, 王一凡, Laurent Charlin, 张明, 和唐健。2019.基于会话的社交 , 通过动态图注意网络进行推荐。In *WSDM*.555-563.
- [96] Younghun Song and Jae-Gil Lee。2018.用高阶用户上下文 , 为基于会话的推荐增强递归神经网络。 *arXiv 预印本 arXiv:1805.02983* (2018)。
- [97] Gabriele Sottocornola, Panagiotis Symeonidis, and Markus Zanker.2018.基于会话的新闻推荐。在 *WWW*.1395-1399.
- [98] Nitish Srivastava, Geoffrey Hinton, Alex Krizhevsky, Ilya Sutskever, and Ruslan Salakhutdinov.2014.Dropout : 防止神经网络过拟合的简单方法。 *The Journal of Machine Learning Research* 15, 1 (2014), 1929-1958.
- [99] 孙飞, 刘军, 吴健, 裴长华, 肖林, 欧文武, 姜鹏。2019.BERT4Rec:顺序 , 用变压器的双向编码器表示推荐 。 In *CIKM*.1441-1450.
- [100] 孙世明, 唐元和, 戴泽梅, 和周福。2019.Self-Attention Network for Session-Based Recommendation With Streaming Data Input. *IEEE Access* (2019).
- [101] Zhu Sun, Qing Guo, Jie Yang, Hui Fang, Guibing Guo, Jie Zhang, and Robin Burke.2019.关于带有侧面信息的推荐的研究评论。A survey and research directions. *Electronic Commerce Research and Applications* 37 (2019), 100879.
- [102] 朱新, 于迪, 方慧, 杨杰, 张杰曲星华, 耿聪。2020年, 我们是否在进行严格的评估? Reproducible Evaluation and Fair Comparison的基准测试建议。In *Recsys*.
- [103] Yong Kiam Tan, Xinxing Xu, and Yong Liu.2016.用于基于会话的推荐的改进的递归神经网络 dations.在 *第一届推荐系统深度学习研讨会* 上。17-22.
- [104] 唐金辉, 杜晓宇, 何湘南, 袁法杰, 田琦, 蔡达生。2019.面向 鲁棒性多媒体推荐系统的对抗性训练。 *TKDE* (2019)。
- [105] 唐嘉熙和王珂。2018.通过卷积序列嵌入的个性化top-n顺序推荐。In *WSDM*.565-573.
- [106] Yi Tay, Luu Anh Tuan, and Siu Cheung Hui.2018.通过基于记忆的注意力进行潜关系度量学习 , 用于 协作排名。In *WWW*.729-739.
- [107] Trinh Xuan Tuan 和 Tu Minh Phuong.2017.用于基于会话的推荐的三维卷积网络与 内容特征。In *RecSys*.138-146.
- [108] 巴特沃米耶·沃托斯基。2016.在会话感知的推荐系统中用神经 网络对上下文信息进行建模。In *RecSys*.273-276.
- [109] Vladimir Vapnik and Akshay Vashist。2009.一种新的学习范式。使用特权信息的学习。 *神经网络* 22, 5-6 (2009) , 544-557。
- [110] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin.2017.注意力是你所需要的一切。在 *NIPS*。5998-6008.
- [111] Mengting Wan, Di Wang, Jie Liu, Paul Bennett, and Julian McAuley.2018.代表和推荐具有互补性、兼容性和忠诚度的购物篮。在 *CIKM*。美国计算机协会, 纽约, 美国。 <https://doi.org/10.1145/3269206.3271786>

- [112] 万胜贤, 蓝艳艳, 王鹏飞, 郭佳峰, 徐俊, 程学启. 2015. 用神经网络推荐下一个篮子. In *RecSys Posters*.
- [113] 王晨阳, 张敏, 马伟志, 刘益群, 马少平. 2019. 为推荐系统的重复消费建立项目特定的时间 动态模型. In *WWW*.1977-1987.
- [114] 王浩宇, 连德福, 和葛勇. 2019. 用蒸馏图卷积 网络进行二值化协同过滤. *arXiv 预印本* arXiv:1906.01829 (2019) .
- [115] Hao Wang, Naiyan Wang, and Dit-Yan Yeung. 2015. 用于推荐系统的协作式深度学习. In *KDD*.1235-1244.
- [116] Hao Wang, SHI Xingjian, and Dit-Yan Yeung. 2016. 协作式递归自动编码器. 推荐同时学习 , 以填补空白. In *NIPS*.415-423.
- [117] 王鹏飞, 陈汉雄, 朱亚东, 沈华伟, 张永峰. 2019. 统一的协作过滤 over Graph Embeddings. In *SIGIR*.155-164.
- [118] 王鹏飞, 郭佳峰, 兰艳艳, 徐俊, 万胜先, 程学启. 2015. 为下一个篮子推荐学习分层的 表示模型. In *SIGIR*.403-412.
- [119] 王守金, 曹龙兵, 和王艳. 2019. A survey on session-based recommender systems. *arXiv preprint arXiv:1902.04864* (2019) .
- [120] 王守金, 胡亮, 曹龙兵, 黄小水, 连德福, 和刘伟. 2018. 基于注意力的事务性 上下文嵌入下一个项目的推荐. In *AAAI*.2532-2539.
- [121] 王守金, 胡亮, 王艳, 曹龙兵, 盛泉子, 和 Mehmet Orgun. 2019. 顺序推荐器 系统: 挑战、进展和前景. In *IJCAI/AAAI* 出版社, 6332-6338.
- [122] 王守金, 胡亮, 王燕, 盛泉, Mehmet A. Orgun, 和曹龙兵. 2019. 通过混合通道目的路由网络为下一个项目推荐的多目的会话建模. In *IJCAI*.3771-3777.
- [123] 王文杰, 冯富礼, 何湘南, 聂立强, 蔡达生. 2020. 推荐的去噪隐性反馈. *arXiv 预印本* arXiv:2006.04153 (2020) .
- [124] 王翔, 徐耀坤, 何向南, 曹一心, 王萌, 蔡达生. 2020. Reinforced Negative Sampling over Knowledge Graph for Recommendation. In *WWW*.99-109.
- [125] 王亚青, 姚全明, James T Kwok, 和 Lionel M Ni. 2020. 从少数例子中归纳. 关于 几次学习的调查. *CSUR* (2020), 1-34.
- [126] 王紫阳, 魏巍, 高聪, 李晓丽, 毛先玲, 邱明辉. 2020. 全局上下文增强 图神经网络的基于会话的推荐. 在 *CIKM*.169-178.
- [127] 魏健, 何建华, 陈凯, 周毅, 唐作银. 2016. 基于协作过滤和深度学习的 混合推荐的冷启动问题. 在 *DASC/PiCom/DataCom/CyberSciTech*.874-877.
- [128] 陈武和严明. 2017. 用于电子商务产品推荐的会话感知信息嵌入. 在 *CIKM*.2379-2382.
- [129] Chao-Yuan Wu, Amr Ahmed, Alex Beutel, Alexander J Smola, and How Jing. 2017. 递归推荐人网络. 在 *WSDM*.495-503.
- [130] 吴启天, 高一瑞, 高晓峰, 翁保罗, 陈桂海. 2019. 双序列预测模型连接 序列推荐和信息传播. In *KDD*.447-457.
- [131] Shu Wu, Yuyuan Tang, Yanqiao Zhu, Liang Wang, Xing Xie, and Tieniu Tan. 2019. 基于会话的推荐 与图神经网络. In *AAAI*, Vol. 33.346-353.
- [132] Yao Wu, Christopher DuBois, Alice X Zheng, and Martin Ester. 2016. 协作去噪自动编码器用于top-n 推荐系统. 在 *WSDM*中. 153-162.
- [133] 夏巧林, 姜鹏, 孙飞, 张毅, 王小波, 隋志芳. 2018. 基于多任务深度学习的消费者购买决策建模 , 用于推荐. 在 *CIKM*.1703-1706.
- [134] Longqi Yang, Cheng-Kang Hsieh, Hongjian Yang, John P Pollak, Nicola Dell, Serge Belongie, Curtis Cole, and Deborah Estrin. 2017. Yum-me : 一个基于营养素的个性化膳食推荐系统. *tois* 36, 1 (2017), 1-31.
- [135] 杨一丁, 邱家彦, 宋明理, 陶大成, 王新潮. 2020. 从图中提炼知识 卷积网络. In *CVPR*.7074-7083.
- [136] 杨震, 丁明, 周昌, 杨红霞, 周敬仁, 唐杰. 2020. 了解图表示学习中的负 采样. 在 *KDD*.
- [137] Haochao Ying, Fuzhen Zhuang, Fuzheng Zhang, Yanchi Liu, Guandong Xu, Xing Xie, Hui Xiong, and Jian Wu. 2018. 基于分层注意力网络的顺序推荐系统. In *IJCAI*.
- [138] 游佳璇, 王一辰, Aditya Pal, Pong Eksombatchai, Chuck Rosenberg, 和 Jure Leskovec. 2019. Hierarchical temporal convolutional networks for dynamic recommender systems. In *WWW*.2236-2246.
- [139] 虞锋, 刘强, 吴曙, 王亮, 谭铁牛. 2016. 一个用于下一个篮子推荐的动态递归模型. In *SIGIR*.729-732.

- [140] 陆宇, 张初旭, 梁尚松, 张祥良. 2019.用于 顺序推荐的多序殷勤排名模型. In *AAAI*, Vol. 33.5709-5716.
- [141] 袁法杰, 何向南, 蒋浩川, 郭贵兵, 熊健, 徐哲钊, 熊一林. 2020.未来数据 帮助训练.为基于会话的推荐建立未来情境模型. In *WWW*.303-313.
- [142] Fajie Yuan, Alexandros Karatzoglou, Ioannis Arapakis, Joemon M Jose, and Xiangnan He.2019.一个简单的卷积 生成网络的下一个项目推荐.在 *WSDM*中. 582-590.
- [143] 袁锋, 姚丽娜, 和Boualem Benatallah. 2019.Adversarial Collaborative Neural Network for Robust Recommendation.In *SIGIR*.
- [144] 张鸣戈和杨振宇. 2019.GACOforRec:Session-Based Graph Convolutional Neural Networks Recommendation Model.*IEEE Access* (2019).
- [145] 张琦, 王嘉文, 黄浩然, 黄璇晶, 和龚业云. 2017. 多模态微博的标签推荐, 使用共同注意力网络. In *IJCAI*.3420-3426.
- [146] Shuai Zhang, Yi Tay, Lina Yao, Aixin Sun, and Jake An. 2019.用自我关注的指标推荐下一个项目 学习. In *AAAI*, Vol. 9.
- [147] 张帅, 姚丽娜, 孙爱新, 和郑毅. 2019.基于深度学习的推荐系统. A survey and new perspectives.*ACM 计算调查 (CSUR)* 52, 1 (2019), 5.
- [148] 张永峰和陈旭. 2018.可解释的推荐. a survey and new perspectives. *arXiv preprint arXiv:1804.11192* (2018).
- [149] 张宇, 戴汉军, 徐昌, 冯俊, 王泰峰, 边江, 王斌, 和刘铁岩. 2014.用递归神经网络对赞助搜索进行序列 点击预测。在 *AAAI*。
- [150] 张扬, 冯富礼, 王晨旭, 何湘南, 王萌, 李艳, 张永东. 2020.如何重新训练 推荐系统? 一种连续的元学习方法. In *SIGIR*.
- [151] Wei Zhao, Benyou Wang, Min Yang, Jianbo Ye, Zhou Zhao, Xiaojun Chen, and Ying Shen.2019.Leveraging Long and Short-Term Information in Content-Aware Movie Recommendation via Adversarial Training.*IEEE Transactions on Cybernetics* (2019).
- [152] 赵哲, 程志远, 洪立昌, 和池爱华. 2015.通过行为 因式分解改进用户主题兴趣档案. In *WWW*.1406-1416.
- [153] Chang Zhou, Jinze Bai, Junshuai Song, Xiaofei Liu, Zhengchao Zhao, Xiusi Chen, and Jun Gao.2018.ATRank:一个, 基于注意力的用户行为建模的推荐框架.在 *AAAI*。
- [154] 周杰, 崔甘泉, 张正彦, 杨成, 刘志远, 孙茂松. 2018.图神经网络:方法和应用的 回顾. *arXiv 预印本 arXiv:1812.08434* (2018)。
- [155] Fuzhen Zhuang, Yingmin Zhou, Fuzheng Zhang, Xiang Ao, Xing Xie, and Qing He.2017.顺序转移学习: 用于推荐的跨领域新颖性寻求特质挖掘. In *WWW Companion*.881-882.